

رسالة محمد



یادگیری ماشین

مدرس: محمدرضا محمدی

زمستان ۱۴۰۱

چالش‌های اصلی یادگیری ماشین

- وظیفه اصلی انتخاب **مدل** و آموزش آن بر روی مقداری **داده** است

Conventional model-centric approach:

$$\text{AI} = \text{Code} + \text{Data}$$

(algorithm/model)

Work on this

Data-centric approach:

$$\text{AI} = \text{Code} + \text{Data}$$


(algorithm/model)

Work on this

چالش‌های داده


- تعداد ناکافی داده‌های آموزشی

- مقالات متعددی داریم که به اهمیت حجم مجموعه داده تاکید می‌کنند



چالش‌های داده

- تعداد ناکافی داده‌های آموزشی
- داده‌های آموزشی غیرنماینده (Nonrepresentative)
 - برای تعمیم خوب، بسیار مهم است که داده‌های آموزشی نماینده مناسبی از داده‌ها باشند
 - اگر داده‌ها کم باشد، نویز نمونه‌برداری خواهیم داشت و حتی اگر خیلی زیاد باشد، ممکن است بایاس نمونه‌برداری داشته باشیم



چالش‌های داده

- تعداد ناکافی داده‌های آموزشی
- داده‌های آموزشی غیرنماینده
- داده‌های با کیفیت پایین

- اگر داده‌های آموزشی مملو از نمونه‌های پرت، خطا و نویز باشد، تشخیص الگوهای اصلی برای سیستم سخت‌تر می‌شود

- معمولاً زمان قابل توجهی به پاک‌سازی داده‌ها (data cleaning) اختصاص داده می‌شود

Labeled Faces in the Wild



Menu

- LFW Home
 - Explore
 - Download
 - Train/Test
 - Results
 - Information
 - Errata
 - Reference
 - Resources
 - Contact
 - Support
 - Changes
- Part Labels
- UMass Vision

Labeled Faces in the Wild Home



• [Recep_Tayyip_Erdogan_0004](#) is incorrect (it is an image of Abdullah Gul):



چالش‌های داده

- تعداد ناکافی داده‌های آموزشی

- داده‌های آموزشی غیرنماینده


- داده‌های با کیفیت پائین

- ویژگی‌های غیرمرتبط (Irrelevant)


- سیستم تنها زمانی قادر به یادگیری خواهد بود که داده‌های آموزشی دارای ویژگی‌های مرتبط کافی باشد و موارد نامربوط زیاد نباشد

- انتخاب ویژگی (Feature Selection)

- استخراج ویژگی (Feature Extraction)




feature extraction



feature selection


بیش‌برازش (Overfitting)

- مدل روی داده‌های آموزشی به خوبی عمل می‌کند، اما به خوبی برای داده‌های جدید تعمیم نمی‌دهد
- مدل‌های پیچیده مانند شبکه‌های عصبی عمیق می‌توانند الگوهای ظریف را در داده‌ها تشخیص دهند
 - اگر مجموعه آموزشی دارای نویز باشد یا خیلی کوچک باشد (نویز نمونه‌برداری)، مدل احتمالاً الگوهایی را در خود نویز تشخیص می‌دهد
 - چنین الگوهایی قابل تعمیم نیست!





بیش‌برازش (Overfitting)

- به عنوان مثال فرض کنید کاراکترهای نام یک کشور هم به عنوان ویژگی استفاده شود
 - در نمونه‌های آموزشی، New Zealand، Norway، Sweden و Switzerland دارای حرف **w** و رضایت بیش از ۷ هستند
 - آیا این الگو قابل تعمیم است؟!
 - کشورهای Rwanda و Zimbabwe؟
- بیش‌برازش زمانی اتفاق می‌افتد که مدل نسبت به مقدار و نویز داده‌های آموزشی بسیار پیچیده باشد




Overfitting vs Underfitting




انتخاب مدل


- در یادگیری ماشین، هدف ما کشف الگوها است
- اما چگونه می‌توانیم مطمئن باشیم که واقعاً یک الگوی عمومی را کشف کرده‌ایم و صرفاً داده‌های خود را حفظ نکرده‌ایم؟



ارزیابی مدل‌های یادگیری ماشین


- در یادگیری ماشین، هدف دستیابی به مدل‌هایی است که بتوانند تعمیم‌دهی خوبی داشته باشند و بر روی داده‌هایی که قبلاً ندیده‌اند به خوبی عمل کنند
- بسیار مهم است که بتوانیم قدرت تعمیم‌دهی مدل را به طور قابل اعتماد اندازه‌گیری کنیم
- ارزیابی یک مدل با تقسیم داده‌های موجود به سه بخش انجام می‌شود:
 - آموزشی (training)
 - اعتبارسنجی (validation)
 - آزمون (test)






ارزیابی مدل‌های یادگیری ماشین

- آموزش بر روی داده‌های آموزشی انجام می‌شود (برای بهینه‌سازی پارامترها)
- مدل بر روی داده‌های اعتبارسنجی ارزیابی می‌شود (برای تنظیم ابرپارامترها)
 - دلیل این است که توسعه یک مدل همیشه شامل تنظیم پیکربندی آن است
 - تنظیم ابرپارامترهای شبکه یک نوع یادگیری است
 - با وجود آنکه از داده‌های اعتبارسنجی برای آموزش پارامترهای شبکه هیچ استفاده‌ای نمی‌شود، اما این امکان وجود دارد که مدل به داده‌های اعتبارسنجی overfit شود
- مدل نهایی را فقط یک بار بر روی داده‌های آزمون ارزیابی می‌کنیم




اعتبارسنجی Hold-out



- اگر داده‌های کمی در دسترس باشد، مجموعه‌های اعتبارسنجی و آزمون ممکن است نمونه‌های بسیار کمی داشته باشند و نتوانند از نظر آماری نماینده خوبی برای داده‌های مورد نظر باشند
- تقسیم‌بندی تصادفی داده‌ها باعث خواهد شد نتایج بسیار متفاوتی از عملکرد مدل بدست بیاید

اعتبارسنجی متقابل K-fold

- مجموعه داده را به K بخش با اندازه مشابه تقسیم می‌کنیم
- برای هر بخش i ، یک مدل با استفاده از داده‌های $K - 1$ بخش دیگر آموزش می‌بیند و بر روی داده‌های بخش i ارزیابی می‌شود
- امتیاز نهایی با استفاده از این K آزمایش محاسبه می‌شود



عدم تطابق داده‌ها

- در برخی موارد، به راحتی می‌توان حجم زیادی از داده‌ها را برای آموزش بدست آورد
 - اما این داده‌ها احتمالاً نمایانگر داده‌هایی نیستند که در محصول استفاده می‌شوند
 - برای مثال، فرض کنید می‌خواهید یک اپلیکیشن برای شناسایی گل‌ها ایجاد کنید
 - می‌توانید میلیون‌ها تصویر از گل‌ها را به راحتی در وب دانلود کنید
 - اما این تصاویر کاملاً نمایانگر تصاویری نیستند که در واقع با استفاده از برنامه روی تلفن همراه گرفته می‌شوند
 - فرض کنید فقط ۱۰۰۰ تصویر نماینده داشته باشید (یعنی واقعاً با برنامه گرفته شده است)
 - داده‌های اعتبارسنجی و ارزیابی باید نماینده‌های خوبی برای داده‌های مورد استفاده در محصول باشند
 - اگر دقت روی داده‌های اعتبارسنجی خوب نباشد، ممکن است مدل روی داده‌های آموزشی overfit شده باشد یا آنکه داده‌ها تطابق نداشته باشند
 - برای تشخیص مناسب است تا بخشی داده اعتبارسنجی مشابه با داده‌های آموزشی هم داشته باشیم

عدم تطابق داده‌ها

- اگر دقت مدل روی Train-dev مناسب نباشد، مدل overfit شده است که باید حل شود
- اگر دقت مدل روی Train-dev مناسب اما روی Dev نامناسب باشد، باید عدم تطابق داده‌ها را حل کرد

