

رسالة محمد



یادگیری ماشین

مدرس: محمدرضا محمدی

زمستان ۱۴۰۱

آموزش مدل‌ها

Training Models

Logistic Regression

$$\hat{p} = h_{\theta}(\mathbf{x}) = \sigma(\theta^T \mathbf{x})$$

$$\sigma(t) = \frac{1}{1 + \exp(-t)}$$

$$\hat{y} = \begin{cases} 0 & \text{if } \hat{p} < 0.5 \\ 1 & \text{if } \hat{p} \geq 0.5 \end{cases}$$

$$c(\theta) = \begin{cases} -\log(\hat{p}) & \text{if } y = 1 \\ -\log(1 - \hat{p}) & \text{if } y = 0 \end{cases}$$

- با این تابع می‌توان احتمال تعلق $\mathbf{x}$ به کلاس ۱ را محاسبه کرد

- توجه شود که $\sigma(t) < 0.5$ در $t < 0$ اتفاق می‌افتد
- $\theta^T \mathbf{x} = 0$ معادل با احتمال 0.5 است و مرز تصمیم را مشخص می‌کند

- از تابع هزینه Cross Entropy استفاده می‌کنیم

Logistic Regression

$$J(\boldsymbol{\theta}) = -\frac{1}{m} \sum_{i=1}^m \left[y^{(i)} \log(\hat{p}^{(i)}) + (1 - y^{(i)}) \log(1 - \hat{p}^{(i)}) \right]$$


- پاسخ بسته‌ای برای یافتن مینیمم این تابع محاسبه نشده است
- اما این تابع محدب است، بنابراین با استفاده از GD می‌توان نقطه بهینه سراسری آن را بدست آورد

$$\frac{\partial}{\partial \theta_j} J(\boldsymbol{\theta}) = \frac{1}{m} \sum_{i=1}^m \left(\sigma(\boldsymbol{\theta}^\top \mathbf{x}^{(i)}) - y^{(i)} \right) x_j^{(i)}$$

- برای هر نمونه، خطای پیش‌بینی را محاسبه می‌کند و آن را در مقدار ویژگی x_j ضرب می‌کند

مرزهای تصمیم

- برای شبیه‌سازی از مجموعه داده iris استفاده می‌کنیم
- این مجموعه داده شامل ۴ ویژگی (عرض و ارتفاع کاسبرگ و گلبرگ) از ۱۵۰ گل زنبق از ۳ کلاس مختلف است



```
>>> from sklearn.datasets import load_iris
>>> iris = load_iris(as_frame=True)
>>> list(iris)
>>> iris.data.head(3)
   sepal length (cm)  sepal width (cm)  petal length (cm)  petal width (cm)
0                5.1                3.5                1.4                0.2
1                4.9                3.0                1.4                0.2
2                4.7                3.2                1.3                0.2
>>> iris.target.head(3) # note that the instances are not shuffled
0    0
1    0
2    0
```

مرزهای تصمیم

- فرض کنید می‌خواهیم یک دسته‌بند برای تشخیص گل‌های virginica تنها با استفاده از عرض گلبرگ آموزش بدهیم

```
from sklearn.linear_model import LogisticRegression
from sklearn.model_selection import train_test_split
```


```
X = iris.data[["petal width (cm)"]].values
y = iris.target_names[iris.target] == 'virginica'
X_train, X_test, y_train, y_test = train_test_split(X, y, random_state=42)
```

```
log_reg = LogisticRegression(random_state=42)
log_reg.fit(X_train, y_train)
```

```
X_new = np.linspace(0, 3, 1000).reshape(-1, 1)
y_proba = log_reg.predict_proba(X_new)
decision_boundary = X_new[y_proba[:, 1] >= 0.5][0, 0]
```

```
>>> decision_boundary
1.6516516516516517
```

```
>>> log_reg.predict([[1.7], [1.5]])
array([ True, False])
```




مرزهای تصمیم

- حال همان مسئله را با استفاده از دو ویژگی بررسی می کنیم

$$\hat{p} = h_{\theta}(\mathbf{x}) = \sigma(\theta^T \mathbf{x})$$

- مرز تصمیم به چه صورتی است؟



Softmax Regression

- مدل logistic regression می تواند به سادگی برای دسته بندی چند کلاسه تعمیم داده شود
 - بدون نیاز به آموزش و ترکیب چندین دسته بند باینری

- برای هر کلاس، یک تابع امتیاز $s_k(\mathbf{x})$ آموزش داده می شود و سپس با نرمال سازی، یک احتمال برای هر کلاس تخمین زده می شود

$$s_k(\mathbf{x}) = (\boldsymbol{\theta}^{(k)})^\top \mathbf{x}$$

- هر کلاس بردار پارامترهای خاص $\boldsymbol{\theta}^{(k)}$ خودش را دارد
- مجموع احتمال ها برابر با ۱ است

$$\hat{p}_k = \sigma(\mathbf{s}(\mathbf{x}))_k = \frac{\exp(s_k(\mathbf{x}))}{\sum_{j=1}^K \exp(s_j(\mathbf{x}))}$$

$$\hat{y} = \operatorname{argmax}_k \sigma(\mathbf{s}(\mathbf{x}))_k = \operatorname{argmax}_k s_k(\mathbf{x}) = \operatorname{argmax}_k ((\boldsymbol{\theta}^{(k)})^\top \mathbf{x})$$

Softmax Regression

- تابع هزینه مناسب برای این مدل، تابع Cross Entropy است
- برای حالت دو کلاسه دقیقا مشابه با BCE است

$$J(\Theta) = -\frac{1}{m} \sum_{i=1}^m \sum_{k=1}^K y_k^{(i)} \log(\hat{p}_k^{(i)})$$


$$\nabla_{\Theta}^{(k)} J(\Theta) = \frac{1}{m} \sum_{i=1}^m (\hat{p}_k^{(i)} - y_k^{(i)}) \mathbf{x}^{(i)}$$

- بردار گرادیان برای وزنهای کلاس k :

```
X = iris.data[["petal length (cm)", "petal width (cm)"]].values  
y = iris["target"]  
X_train, X_test, y_train, y_test = train_test_split(X, y, random_state=42)
```

```
softmax_reg = LogisticRegression(C=30, random_state=42)  
softmax_reg.fit(X_train, y_train)
```

```
>>> softmax_reg.predict([[5, 2]])  
array([2])  
>>> softmax_reg.predict_proba([[5, 2]]).round(2)  
array([[0.   , 0.04, 0.96]])
```



مدل‌های خطی

- در این فصل، روش‌های مختلفی برای آموزش مدل‌های خطی (هم برای رگرسیون و هم برای دسته‌بندی) بررسی شد

- برای رگرسیون خطی پاسخ بسته محاسبه شد $\hat{\boldsymbol{\theta}} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y} = \mathbf{X}^+ \mathbf{y}$

- استفاده از گرادیان کاهشی (و نسخه‌های stochastic آن) بررسی شد $\boldsymbol{\theta}^{(\text{next step})} = \boldsymbol{\theta} - \eta \nabla_{\boldsymbol{\theta}} \text{MSE}(\boldsymbol{\theta})$

- با استفاده از طراحی ویژگی‌های غیرخطی، می‌توان به توابع غیرخطی با استفاده از مدل‌های خطی رسید

- افزودن عبارت‌های برای جریمه کردن مقادیر نامناسب برای وزن‌ها بررسی شد $J(\boldsymbol{\theta}) = \text{MSE}(\boldsymbol{\theta}) + \frac{\alpha}{m} \sum_{i=1}^n \theta_i^2$

- رگرسیون‌های Logistic و Softmax برای دسته‌بندی خطی معرفی شد $\hat{p} = h_{\boldsymbol{\theta}}(\mathbf{x}) = \sigma(\boldsymbol{\theta}^T \mathbf{x})$



$$\hat{p}_k = \sigma(\mathbf{s}(\mathbf{x}))_k = \frac{\exp(s_k(\mathbf{x}))}{\sum_{j=1}^K \exp(s_j(\mathbf{x}))}$$

ماشین‌های بردار پشتیبان

Support Vector Machines



SVM خطی برای دسته‌بندی

- کدام مرز تصمیم مناسب‌تر است؟
- داده‌های این مسئله به صورت خطی جداپذیر است (linearly separable) و هر دو خط قرمز و بنفش روی داده‌های آموزشی دقت کامل دارند
- ایده اساسی SVM این است که مرز حاصل، حداکثر فاصله را با نزدیک‌ترین نمونه‌های آموزشی داشته باشد
- دسته‌بندی با حاشیه بزرگ (large margin) نامیده می‌شود





SVM خطی برای دسته‌بندی

- به نمونه‌هایی که کمترین فاصله تا مرز را دارند، بردار پشتیبان (support vector) گفته می‌شود
- افزودن نمونه‌هایی به مجموعه داده که خارج از این حاشیه باشند ("off the street")، تاثیری در مرز تصمیم ندارند





SVM خطی برای دسته‌بندی

- آیا مقیاس ویژگی‌ها در تعیین بردارهای پشتیبان موثر است؟
 - بله! استانداردسازی ویژگی‌ها مهم است



حاشیه نرم (Soft Margin)

- در حالت حاشیه سخت (hard)، حساست نسبت به داده‌های پرت بسیار زیاد است و حتی مسائلی که به صورت خطی جداپذیر نیستند قابل استفاده نیست
- در حاشیه نرم، کمی منعطف‌تر رفتار می‌شود و سعی می‌شود حاشیه تا حد امکان زیاد باشد و نمونه‌هایی که از حاشیه عبور می‌کنند، جریمه ایجاد کنند




SVM خطی برای دسته‌بندی

$$\boldsymbol{\theta}^T \mathbf{x} = \theta_0 x_0 + \cdots + \theta_n x_n = \mathbf{w}^T \mathbf{x} + b = w_1 x_1 + \cdots + w_n x_n + b$$

$$\hat{y} = \begin{cases} 0 & \text{if } \boldsymbol{\theta}^T \mathbf{x} < 0.5 \\ 1 & \text{if } \boldsymbol{\theta}^T \mathbf{x} \geq 0.5 \end{cases}$$

• چگونه وزن‌های مربوط به خط دارای بیشترین حاشیه را بدست بیاوریم؟

- حاشیه را جایی تعیین می‌کنیم که $\boldsymbol{\theta}^T \mathbf{x} = \pm 1$ شود
- بیشترین حاشیه زمانی بدست می‌آید که $\mathbf{w}$ کمترین مقدار را داشته باشد
- در حاشیه سخت، هیچکدام از نمونه‌ها نباید از حاشیه عبور کنند
- مسئله بهینه‌سازی مقید زیر را باید حل کنیم:



$$\underset{\mathbf{w}, b}{\text{minimize}} \quad \frac{1}{2} \mathbf{w}^T \mathbf{w}$$

$$\text{subject to} \quad t^{(i)}(\mathbf{w}^T \mathbf{x}^{(i)} + b) \geq 1 \quad \text{for } i = 1, 2, \dots, m$$

$$t^{(i)} = \begin{cases} -1 & \text{if } y^{(i)} = 0 \\ +1 & \text{if } y^{(i)} = 1 \end{cases}$$

حاشیه نرم

$$\begin{aligned} & \underset{\mathbf{w}, b}{\text{minimize}} && \frac{1}{2} \mathbf{w}^\top \mathbf{w} \\ & \text{subject to} && t^{(i)} (\mathbf{w}^\top \mathbf{x}^{(i)} + b) \geq 1 \quad \text{for } i = 1, 2, \dots, m \end{aligned}$$

• در حاشیه نرم، اجازه داده می شود تا برخی نمونه ها بتوانند حاشیه را بشکنند

- متناسب با شکستن حاشیه، به تابع هزینه افزوده می شود

$$\begin{aligned} & \underset{\mathbf{w}, b, \zeta}{\text{minimize}} && \frac{1}{2} \mathbf{w}^\top \mathbf{w} + C \sum_{i=1}^m \zeta^{(i)} \\ & \text{subject to} && t^{(i)} (\mathbf{w}^\top \mathbf{x}^{(i)} + b) \geq 1 - \zeta^{(i)} \quad \text{and} \quad \zeta^{(i)} \geq 0 \quad \text{for } i = 1, 2, \dots, m \end{aligned}$$

