

رسالة محمد

یادگیری ماشین


مدرس: محمدرضا محمدی

بهار ۱۴۰۲

شبکه‌های عصبی مصنوعی

Artificial Neural Networks

یادگیری عمیق




شبکه‌های عصبی مصنوعی

- مشابه با بسیاری از اختراعات بشری، شبکه‌های عصبی مصنوعی از نحوه عملکرد مغز موجودات زنده الهام گرفته است
- اگرچه هواپیماها از پرندگان الهام گرفته‌اند، اما مجبور نیستند برای پرواز بال بزنند
 - به طور مشابه، ANNها به تدریج با الگوهای بیولوژیکی خود کاملاً متفاوت شده‌اند
 - به واحدهای مورد استفاده در شبکه‌های عصبی مصنوعی بعضاً نورون (neuron) و بعضاً واحد (unit) گفته می‌شود



شبکه‌های عصبی مصنوعی

- شبکه‌های عصبی مصنوعی در ابتدا توجهات بسیار زیادی را به خود جلب کرد و مدل‌های مختلفی پیشنهاد شدند
- اما چالش‌هایی که برای حل مسائل واقعی داشت، باعث شد تا مدتی از مرکز توجه خارج شوند



دلایل موفقیت یادگیری عمیق در سال‌های اخیر

- بسیاری از الگوریتم‌ها قدیمی هستند

- CNN و backpropagation: ۱۹۸۹



- LSTM: ۱۹۹۷

- سخت‌افزارهای قدرتمند و مجموعه‌داده‌های بزرگ بسیار موثر بوده‌اند

Decade	Dataset	Memory	Floating point calculations per second
1970	100 (Iris)	1 KB	100 KF (Intel 8080)
1980	1 K (House prices in Boston)	100 KB	1 MF (Intel 80186)
1990	10 K (optical character recognition)	10 MB	10 MF (Intel 80486)
2000	10 M (web pages)	100 MB	1 GF (Intel Core)
2010	10 G (advertising)	1 GB	1 TF (Nvidia C2050)
2020	1 T (social network)	100 GB	1 PF (Nvidia DGX-2)

شبکه‌های عصبی

- رگرسیون خطی یک شبکه عصبی یک لایه است
- در این مثال واحد خروجی به تمام واحدهای ورودی متصل است و به آن لایه کاملاً متصل می‌گوئیم
- مدل نورون‌های زیستی از لحاظ ساختاری مشابه با این ساختار است




مدل‌های خطی

- بر فرض یکنواختی دلالت دارد




- هر افزایشی در ویژگی همواره منجر به افزایش (کاهش) خروجی می‌شود اگر وزن مربوطه + (-) باشد
- مثال: احتمال بازپرداخت اقساط بر حسب ویژگی‌هایی شامل درآمد
 - اثر افزایش درآمد از ۰ به ۵ میلیون متناظر با افزایش از ۱۰۰ به ۱۰۵ میلیون است
- مثال: احتمال مرگ بر حسب ویژگی‌هایی شامل دمای بدن
 - هر چه دما بالاتر باشد ریسک بیشتری دارد یا کمتر؟

- استخراج ویژگی قبل از لایه خطی بسیار مهم است



پرسپترون چندلایه

- ساده‌ترین شبکه عمیق است که از چندین لایه کاملاً متصل تشکیل می‌شود
- وظیفه لایه‌های میانی استخراج بازنمایی مناسبی است که مسئله مورد نظر در فضای جدید به صورت خطی قابل حل باشد



پرسپترون چندلایه

$$\mathbf{X} \in \mathbb{R}^{n \times d}$$

$$\mathbf{H} = \mathbf{XW}^{(1)} + \mathbf{b}^{(1)}$$

$$\mathbf{H} \in \mathbb{R}^{n \times h}$$

$$\mathbf{W}^{(1)} \in \mathbb{R}^{d \times h}$$

$$\mathbf{b}^{(1)} \in \mathbb{R}^{1 \times h}$$

$$\mathbf{O} = \mathbf{HW}^{(2)} + \mathbf{b}^{(2)}$$

$$\mathbf{O} \in \mathbb{R}^{n \times q}$$

$$\mathbf{W}^{(2)} \in \mathbb{R}^{h \times q}$$


$$\mathbf{b}^{(2)} \in \mathbb{R}^{1 \times q}$$

$$\mathbf{O} = (\mathbf{XW}^{(1)} + \mathbf{b}^{(1)})\mathbf{W}^{(2)} + \mathbf{b}^{(2)}$$

$$= \mathbf{XW}^{(1)}\mathbf{W}^{(2)} + \mathbf{b}^{(1)}\mathbf{W}^{(2)} + \mathbf{b}^{(2)}$$

$$= \mathbf{XW} + \mathbf{b}$$

• دو لایه خطی متوالی هیچ تفاوتی با یک لایه ندارد



مثال

$$L = \frac{1}{4} \sum_{i=1}^4 (y^{(i)} - \hat{y}^{(i)})^2$$

• تابع ضرر MSE:


$$\hat{y}^{(i)} = \mathbf{w}^T \mathbf{x}^{(i)} + b$$

• مدل خطی:


• با استفاده از بهینه‌سازی تحلیلی به پاسخ زیر می‌رسیم

$$\mathbf{w} = \mathbf{0}, b = 0.5$$

- $L = 0.25$ خواهد شد



مثال



$$L = \frac{1}{4} \sum_{i=1}^4 (y^{(i)} - \hat{y}^{(i)})^2$$



• تابع ضرر MSE:

$$\hat{y}^{(i)} = f^{(2)}(f^{(1)}(\mathbf{x}))$$


• مدل ۲ لایه:

$$\hat{y}^{(i)} = \mathbf{w}^T g(\mathbf{W}^T \mathbf{x}^{(i)} + \mathbf{c}) + b$$

$$\hat{y}^{(i)} = \mathbf{w}^T \max(0, \mathbf{W}^T \mathbf{x}^{(i)} + \mathbf{c}) + b$$



مثال




$$L = \frac{1}{4} \sum_{i=1}^4 (y^{(i)} - \hat{y}^{(i)})^2$$

• تابع ضرر MSE:

• مدل ۲ لایه: $\hat{y}^{(i)} = \mathbf{w}^T \max(0, \mathbf{W}^T \mathbf{x}^{(i)} + \mathbf{c}) + b$

• پاسخ زیر با $L = 0$ قابل محاسبه است






$$\mathbf{W} = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix} \quad \mathbf{w} = \begin{bmatrix} 1 \\ -2 \end{bmatrix}$$

$$\mathbf{c} = \begin{bmatrix} 0 \\ -1 \end{bmatrix} \quad b = 0$$

شبکه‌های عصبی

- ایده اصلی در شبکه‌های عصبی با الهام گرفتن از ساختار مغز انسان این است که یک مسئله پیچیده را در چند مرحله و به صورت سلسله مراتبی حل کنند



پرسپترون چندلایه


- یک شبکه MLP با تابع فعال‌سازی مناسب در لایه‌های میانی و تعداد نورون کافی می‌تواند هر تابعی را پیاده‌سازی کند

- اصطلاحاً Universal Approximator است

- حتی فقط با یک لایه میانی با تعداد نورون به اندازه کافی زیاد


- قسمت سخت کار آموزش وزن‌های مدل است

- برای تقریب بسیاری از توابع می‌توانیم از شبکه‌های عمیق‌تر (بجای عریض‌تر) استفاده کنیم که بسیار فشرده‌تر و کاراتر باشد



توابع فعال سازی



- توابع فعال سازی برای هر نورون مشخص می کنند که خروجی بخشی خطی در چه شرایطی منجر به فعال شدن نورون شود
- به خصوص در شبکه های عمیق بسیار با اهمیت هستند



Sigmoid

- در اولین شبکه‌های عصبی، دانشمندان علاقه‌مند به مدل‌سازی نورون‌های بیولوژیکی بودند که یا فعال می‌شوند یا نمی‌شوند
- با توسعه روش‌های یادگیری مبتنی بر گرادیان، نیاز بود تا تقریب مشتق‌پذیر استفاده شود

$$\text{sigmoid}(x) = \frac{1}{1 + \exp(-x)}$$





Sigmoid

- در بسیاری از مقادیر، گرادیان نزدیک به صفر است که بهینه‌سازی شبکه‌های عمیق را پیچیده می‌کند
- یکی از ایرادات sigmoid این است که خروجی آن همواره مثبت است و بهینه‌سازی را زیگ‌زاگی می‌کند

$$\frac{d}{dx} \text{sigmoid}(x) = \text{sigmoid}(x)(1 - \text{sigmoid}(x))$$

$$\text{sigmoid}(x) = \frac{1}{1 + \exp(-x)}$$





Tanh

- مشابه با تابع Sigmoid خروجی آن محدود است اما به بازه -1 تا $+1$
- اشباع شدن تابع tanh، بهینه‌سازی را دشوار می‌کند و از لحاظ محاسباتی هم به دلیل exp پرهزینه است

$$\frac{d}{dx} \tanh(x) = 1 - \tanh^2(x)$$


$$\tanh(x) = \frac{1 - \exp(-2x)}{1 + \exp(-2x)} = 2\sigma(2x) - 1$$



Rectified Linear Unit (ReLU)

- یک تابع غیرخطی بسیار ساده و پرکاربرد است
- بهینه‌سازی ReLU بسیار آسان است زیرا بسیار شبیه به واحدهای خطی است
- مشتق ReLU برای مقادیری که فعال است همواره بزرگ است

$$\frac{d}{dx} \text{ReLU}(x) = x > 0$$



$$\text{ReLU}(x) = \max(x, 0)$$

