

رسالة محمد



یادگیری ماشین

مدرس: محمدرضا محمدی


بهار ۱۴۰۲

شبکه‌های عصبی مصنوعی

Artificial Neural Networks

توابع فعال سازی


- توابع فعال سازی برای هر نورون مشخص می کنند که خروجی بخشی خطی در چه شرایطی منجر به فعال شدن نورون شود
- به خصوص در شبکه های عمیق بسیار با اهمیت هستند




Rectified Linear Unit (ReLU)

- یک تابع غیرخطی بسیار ساده و پرکاربرد است
- بهینه‌سازی ReLU بسیار آسان است زیرا بسیار شبیه به واحدهای خطی است
- مشتق ReLU برای مقادیری که فعال است همواره بزرگ است

$$\frac{d}{dx} \text{ReLU}(x) = x > 0$$



$$\text{ReLU}(x) = \max(x, 0)$$




ReLU با شیب مخالف صفر

0	0
1	1
2	2
3	3
4	4
5	5
6	6
7	7
8	8
9	9


- تابع قدر مطلق ($g(z) = |z|$) با استفاده از $\alpha_i = -1$
- تابع Leaky ReLU از یک مقدار ثابت کوچک مانند $\alpha_i = 0.01$ استفاده می کند
- نسخه Parametric ReLU (PReLU) α_i را یک متغیر قابل آموزش در نظر می گیرد

$$h_i = g(\mathbf{z}, \boldsymbol{\alpha})_i = \max(0, z_i) + \alpha_i \min(0, z_i)$$


ReLU
 $\max(0, x)$




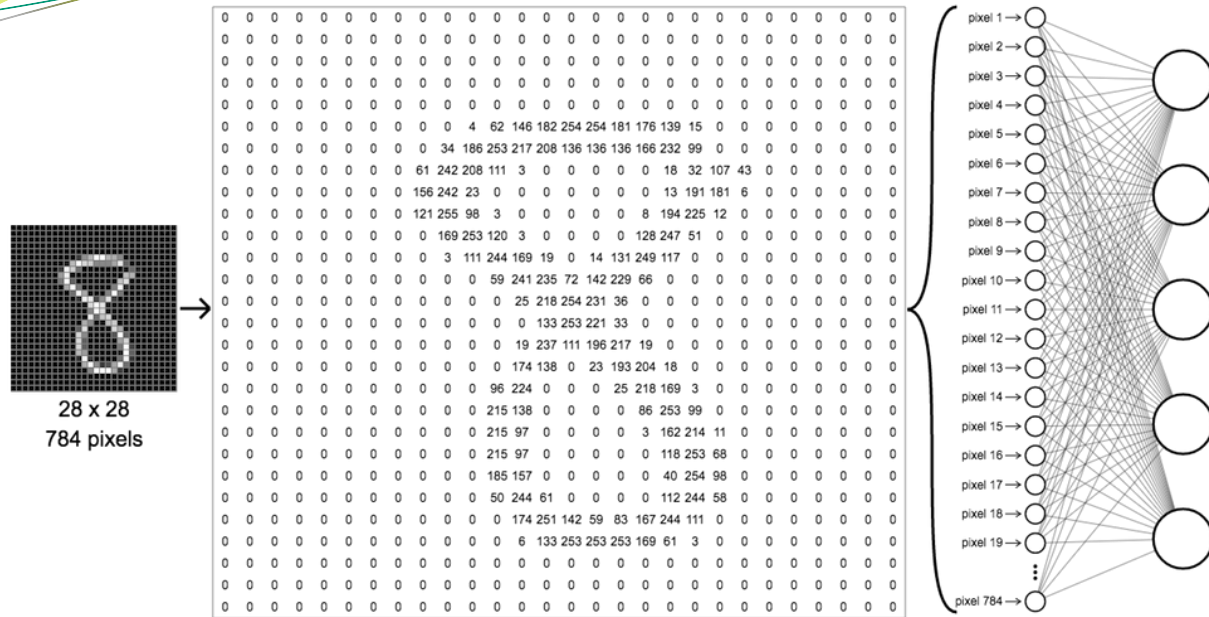
Leaky ReLU
 $\max(0.1x, x)$



لایہ کاملاً متصل



شبکه‌های عصبی




آموزش شبکه‌های عصبی عمیق

Training Deep Neural Networks

چرخه آموزش

- این تنظیم تدریجی، که آموزش نیز نامیده می شود، پایه یادگیری در بسیاری از الگوریتم های یادگیری ماشین است

- یک batch از نمونه های آموزشی x و خروجی های مربوطه y انتخاب می شود
- شبکه بر روی x اعمال می شود (forward pass) تا $\hat{y}$ بدست بیاید
- تابع ضرر شبکه برای این batch از مقایسه y و $\hat{y}$ محاسبه می شود
- تمام وزن های شبکه به گونه ای به روز می شوند که مقدار ضرر برای این batch کمی کاهش بیابد



شبیه‌سازی

- کتابخانه TensorFlow یکی از ابزارهای قدرتمند در حوزه یادگیری عمیق است که امکانات زیادی را در اختیار کاربران قرار می‌دهد و مورد استقبال بسیاری از پژوهشگران است
- در این دوره ما از بخش Keras در TensorFlow برای شبیه‌سازی استفاده می‌کنیم
- برای اجرای کدها از سرویس رایگان Google Colab استفاده می‌کنیم



Keras




محاسبه گرادیان

$$h_i = g(\mathbf{x}^T \mathbf{W}_{:,i} + c_i) = f^{(1)}(\mathbf{x})$$

$$y = f^{(2)}(f^{(1)}(\mathbf{x})) = f(\mathbf{x}; \mathbf{W}, \mathbf{c}, \mathbf{w}, b) = \mathbf{w}^T \max\{0, \mathbf{W}^T \mathbf{x} + \mathbf{c}\} + b$$

$$J(\boldsymbol{\theta}) = \frac{1}{N} \sum (f^*(\mathbf{x}) - f(\mathbf{x}; \mathbf{W}, \mathbf{c}, \mathbf{w}, b))^2$$




- اگر بتوانیم $\frac{\partial J}{\partial \mathbf{W}}$ ، $\frac{\partial J}{\partial \mathbf{c}}$ ، $\frac{\partial J}{\partial \mathbf{w}}$ و $\frac{\partial J}{\partial b}$ را محاسبه کنیم، می‌توانیم پارامترهای مدل را آموزش بدهیم

- اگر بخواهیم تابع ضرر را تغییر بدهیم؟

- نیاز است تا معادلات دوباره از ابتدا استخراج شوند

محاسبه گرادیان

- بسیار خسته کننده است و نیاز به محاسبات ماتریسی فوق العاده زیادی دارد



پس انتشار (Backpropagation)

$$f(x, y, z) = (x + y)z$$

e.g., $x = -2$, $y = 5$, $z = -4$

$$q = x + y \Rightarrow f = qz$$


we want $\frac{\partial f}{\partial x}$ and $\frac{\partial f}{\partial y}$ and $\frac{\partial f}{\partial z}$

$$\frac{\partial f}{\partial q} = z \quad \frac{\partial f}{\partial z} = q$$


Chain rule

$$\frac{\partial f}{\partial x} = \frac{\partial f}{\partial q} \frac{\partial q}{\partial x}$$

$$\frac{\partial f}{\partial y} = \frac{\partial f}{\partial q} \frac{\partial q}{\partial y}$$




پس انتشار (Backpropagation)



مثال: Linear + Sigmoid

$$f(\mathbf{w}, \mathbf{x}) = \frac{1}{1 + e^{-(w_0x_0 + w_1x_1 + w_2)}}$$



$$(1.00) \left(\frac{-1}{1.37^2} \right) = -0.53$$

$$\frac{\partial(ax)}{\partial x} = a$$

$$\frac{\partial(c + x)}{\partial x} = 1$$

$$\frac{\partial(e^x)}{\partial x} = e^x$$

$$\frac{\partial(1/x)}{\partial x} = \frac{-1}{x^2}$$