

به نام خدا



دانشگاه علم و صنعت ایران
دانشکده مهندسی کامپیوتر

یادگیری ماشین

نیمسال دوم ۰۳-۰۴

استاد: جناب آقای دکتر امیرخانی

دستیار استاد: علی اثنی عشری

زمان ارسال: ۲۹ فروردین ماه

تخمین

پاسخ تمرین دوم

- مهلت ارسال پاسخ تا ساعت ۲۳:۵۹ مشخص شده است.
- هم کاری و هم فکری در انجام تمرین مانعی ندارد اما پاسخ ارسالی هر فرد باید توسط خود او نوشته شده باشد.
- در صورت هم فکری یا استفاده از منابع خارج از درس، نام هم فکران و آدرس منابع مورد استفاده را ذکر کنید.
- برای دریافت نمره کامل هر سوال نیاز است تمامی روابط و فرمول ها نوشته شده و توضیحات تشریحی کامل داده شود.
- لطفاً تصویری واضح از پاسخ سوالات نظری بارگذاری کنید. در غیر این صورت پاسخ شما تصحیح نخواهد شد. (برگه پاسخ سوالات نظری به صورت حضوری دریافت می گردد.)
- پاسخ تمام سوالات را در یک فایل فشرده به صورت ML_Hw2_[firstName]_[lastName]_[StudentId] نامگذاری کرده و ارسال کنید.

سوالات نظری

سوال یک (۸ نمره)

فرض کنید تابع چگالی احتمال متغیر تصادفی Y به شکل زیر است.

$$f_Y(y|\theta) = \begin{cases} \frac{1}{\theta} r y^{r-1} e^{-\frac{y}{\theta}}, & \theta > 0, y > 0 \\ 0, & elsewhere \end{cases}$$

که r یک ثابت مثبت است.

الف) تابع $\log \text{likelihood}$ را به دست بیاورید.

پاسخ قسمت الف:

$$\begin{aligned} L(\theta) &= \prod_{i=1}^n f_Y(y_i; \theta) = \prod_{i=1}^n \left(\frac{1}{\theta} r y_i^{r-1} e^{-\frac{y_i^r}{\theta}} \right) \\ &= \left(\frac{r}{\theta} \right)^n \left(\prod_{i=1}^n y_i^{r-1} \right) e^{-\sum_{i=1}^n \frac{y_i^r}{\theta}} \end{aligned}$$

$$\begin{aligned} \Rightarrow \mathcal{L}(\theta) &= \log L(\theta) = \log \left[\left(\frac{r}{\theta} \right)^n \left(\prod_{i=1}^n y_i^{r-1} \right) e^{-\sum_{i=1}^n \frac{y_i^r}{\theta}} \right] \\ &= \underbrace{n \log \left(\frac{\theta}{r} \right)}_{\textcircled{1}} + \underbrace{\log \left(\prod_{i=1}^n y_i^{r-1} \right)}_{\textcircled{2}} - \underbrace{\sum_{i=1}^n \frac{y_i^r}{\theta}}_{\textcircled{3}} \end{aligned}$$

$$\textcircled{1} \Rightarrow n \log \left(\frac{r}{\theta} \right) = n(\log r - \log \theta)$$

$$\textcircled{2} \Rightarrow \log \left(\prod_{i=1}^n y_i^{r-1} \right) = (r-1) \sum_{i=1}^n \log y_i$$

$$\textcircled{3} \Rightarrow - \sum_{i=1}^n \frac{y_i^r}{\theta}$$

$$\Rightarrow \mathcal{L}(\theta) = n \log r - n \log \theta + (r-1) \sum_{i=1}^n \log y_i - \frac{1}{\theta} \sum_{i=1}^n y_i^r$$

ب) توضیح دهید در چه حالتی و چرا تخمین گر مقدار برآورد بیشینه احتمال پسین^۱ به تخمین گر درست‌نمایی بیشینه^۲ میل می‌کند.

پاسخ قسمت ب:

می‌خواهیم بررسی کنیم در چه شرایطی تخمین گر بیشینه احتمال پسین به تخمین گر درست‌نمایی بیشینه میل می‌کند.

فرض کنید مشاهدات $y_1, \dots, y_n$ از توزیع زیر باشند:

$$f_Y(y|\theta) = \frac{r}{\theta} y^{r-1} e^{-\frac{y^r}{\theta}}, \quad \theta > 0, y > 0$$

Maximum A Posteriori Estimation^۱

Maximum Likelihood Estimation^۲

۱. تعریف دو تخمین گر

۱.۱ تخمین گر درست‌نمایی بیشینه :

$$\hat{\theta}_{MLE} = \arg \max_{\theta} L(\theta|y_1, \dots, y_n)$$

۲.۱ تخمین گر احتمال پسین:

$$\hat{\theta}_{posterior} = \arg \max_{\theta} p(\theta|y_1, \dots, y_n)$$

با توجه به قضیه بیز:

$$p(\theta|y) \propto L(\theta|y) \cdot \pi(\theta)$$

۲. حالت تابع پیشین یکنواخت

اگر توزیع پیشین $\pi(\theta)$ ثابت باشد (یعنی $\pi(\theta) = const$)، آنگاه:

$$p(\theta|y) \propto L(\theta|y) \Rightarrow \hat{\theta}_{posterior} = \hat{\theta}_{MLE}$$

۳. حالت تعداد نمونه زیاد

اگر $n \rightarrow \infty$ باشد، حتی اگر توزیع پیشین غیریکسان باشد، اثر آن با بزرگ شدن تابع درست‌نمایی کم می‌شود و نتیجه این خواهد بود که:

$$\hat{\theta}_{posterior} \rightarrow \hat{\theta}_{MLE}$$

سوال دو (۱۲ نمره)

توزیع نرمال $p(x) \sim N(\mu, \sigma^2)$ و پنجره پارزن $\varphi(x) \sim N(0, 1)$ را در نظر بگیرید. نشان دهید که تخمین پنجره پارزن^۳ زیر

$$p(x) = \frac{1}{nh_n} \sum_{i=1}^n \varphi\left(\frac{x - x_i}{h_n}\right)$$

برای h_n های کوچک دارای ویژگی های زیر است :

$$\tilde{p}_n(x) \sim N(\mu, h_n^2 + \sigma^2) \quad (\text{الف})$$

پاسخ قسمت الف:

مقدار امید ریاضی از احتمال در نقطه x بر اساس پارامتر پهنای پنجره h_n ، به صورت زیر تعریف می‌شود:

^۳Parzen Window – based Estimation

$$\begin{aligned}
\bar{p}_n(x) &= \mathcal{E}[p_n(x)] = \frac{1}{nh_n} \sum_{i=1}^n \mathbb{E} \left[\varphi \left(\frac{x - X_i}{h_n} \right) \right] \\
&= \frac{1}{h_n} \int_{-\infty}^{\infty} \varphi \left(\frac{x - v}{h_n} \right) p(v) dv \\
&= \frac{1}{h_n} \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} \exp \left(-\frac{1}{2} \left(\frac{x - v}{h_n} \right)^2 \right) \cdot \frac{1}{\sqrt{2\pi}\sigma} \exp \left[-\frac{1}{2} \left(\frac{v - \mu}{\sigma} \right)^2 \right] dv \\
&= \frac{1}{2\pi h_n \sigma} \exp \left[-\frac{1}{2} \left(\frac{x^2}{h_n^2} + \frac{\mu^2}{\sigma^2} \right) \right] \int_{-\infty}^{\infty} \exp \left[-\frac{1}{2} v^2 \left(\frac{1}{h_n^2} + \frac{1}{\sigma^2} \right) - 2v \left(\frac{x}{h_n^2} + \frac{\mu}{\sigma^2} \right) \right] dv \\
&= \frac{1}{2\pi h_n \sigma} \exp \left[-\frac{1}{2} \left(\frac{x^2}{h_n^2} + \frac{\mu^2}{\sigma^2} \right) + \frac{1}{2} \frac{\alpha^2}{\theta^2} \right] \int_{-\infty}^{\infty} \exp \left(-\frac{1}{2} \left[\frac{v - \alpha}{\theta} \right]^2 \right) dv
\end{aligned}$$

که در آن تعریف کرده‌ایم:

$$\theta^2 = \left(\frac{1}{1/h_n^2 + 1/\sigma^2} \right) = \frac{h_n^2 \sigma^2}{h_n^2 + \sigma^2}$$

و

$$\alpha = \theta^2 \left(\frac{x}{h_n^2} + \frac{\mu}{\sigma^2} \right)$$

با انجام انتگرال گیری، داریم:

$$\begin{aligned}
\bar{p}_n(x) &= \frac{\sqrt{2\pi}\theta}{2\pi h_n \sigma} \exp \left[-\frac{1}{2} \left(\frac{x^2}{h_n^2} + \frac{\mu^2}{\sigma^2} \right) + \frac{1}{2} \frac{\alpha^2}{\theta^2} \right] \\
&= \frac{1}{\sqrt{2\pi} h_n \sigma} \cdot \frac{h_n \sigma}{\sqrt{h_n^2 + \sigma^2}} \exp \left[-\frac{1}{2} \left(\frac{x^2}{h_n^2} + \frac{\mu^2}{\sigma^2} - \frac{\alpha^2}{\theta^2} \right) \right].
\end{aligned}$$

عبارت داخل توان به صورت زیر ساده می‌شود:

$$\begin{aligned}
\frac{x^2}{h_n^2} + \frac{\mu^2}{\sigma^2} - \frac{\alpha^2}{\theta^2} &= \frac{x^2}{h_n^2} + \frac{\mu^2}{\sigma^2} - \frac{\theta^4}{\theta^2} \left(\frac{x}{h_n^2} + \frac{\mu}{\sigma^2} \right)^2 \\
&= \frac{x^2 h_n^2}{(h_n^2 + \sigma^2) h_n^2} + \frac{\mu^2 \sigma^2}{(h_n^2 + \sigma^2) \sigma^2} - \frac{2x\mu}{h_n^2 + \sigma^2} \\
&= \frac{(x - \mu)^2}{h_n^2 + \sigma^2}.
\end{aligned}$$

جای گذاری در معادله اصلی:

$$\bar{p}_n(x) = \frac{1}{\sqrt{2\pi(h_n^2 + \sigma^2)}} \exp\left(-\frac{1}{2} \cdot \frac{(x - \mu)^2}{h_n^2 + \sigma^2}\right)$$

که این همان شکل تابع گاوسی (نرمال) است، و به صورت زیر نمایش داده می شود:

$$\bar{p}_n(x) \sim \mathcal{N}(\mu, h_n^2 + \sigma^2)$$

$$p_n(x) - \tilde{p}_n(x) \approx \frac{1}{2} \left(\frac{h_n}{\sigma}\right)^2 \left[1 - \left(\frac{x - \mu}{\sigma}\right)^2\right] p(x) \quad \text{ب}$$

پاسخ قسمت ب:

واریانس را به صورت زیر محاسبه می کنیم:

$$\begin{aligned}
\text{Var}[p_n(x)] &= \text{Var}\left[\frac{1}{nh_n} \sum_{i=1}^n \varphi\left(\frac{x - x_i}{h_n}\right)\right] \\
&= \frac{1}{n^2 h_n^2} \sum_{i=1}^n \text{Var}\left[\varphi\left(\frac{x - x_i}{h_n}\right)\right] \\
&= \frac{1}{nh_n^2} \text{Var}\left[\varphi\left(\frac{x - v}{h_n}\right)\right] \\
&= \frac{1}{nh_n^2} \left\{ \mathcal{E}\left[\varphi^2\left(\frac{x - v}{h_n}\right)\right] - \left(\mathcal{E}\left[\varphi\left(\frac{x - v}{h_n}\right)\right]\right)^2 \right\}.
\end{aligned}$$

که در اینجا از مستقل بودن نمونه های $X_1, X_2, \dots$ استفاده شده است. برای ادامه، امید ریاضی تابع کرنل به توان دو را محاسبه می کنیم:

$$\begin{aligned}
\mathcal{E} \left[\varphi^2 \left(\frac{x-v}{h_n} \right) \right] &= \int \varphi^2 \left(\frac{x-v}{h_n} \right) p(v) dv \\
&= \int_{-\infty}^{\infty} \frac{1}{2\pi} \exp \left[- \left(\frac{x-v}{h_n} \right)^2 \right] \exp \left[- \frac{1}{2} \left(\frac{v-\mu}{\sigma} \right)^2 \right] \frac{1}{\sqrt{2\pi}\sigma} dv \\
&= \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} \exp \left[- \frac{1}{2} \left(\frac{x-v}{h_n/\sqrt{2}} \right)^2 \right] \exp \left[- \frac{1}{2} \left(\frac{v-\mu}{\sigma} \right)^2 \right] \frac{1}{\sqrt{2\pi}\sigma} dv.
\end{aligned}$$

از قسمت الف و با استدلال مشابه و جایگزینی $\frac{h_n}{\sqrt{2}}$ به جای h_n ، داریم:

$$\begin{aligned}
\frac{1}{h_n/\sqrt{2}} \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} \exp \left[- \frac{1}{2} \left(\frac{x-v}{h_n/\sqrt{2}} \right)^2 \right] \exp \left[- \frac{1}{2} \left(\frac{v-\mu}{\sigma} \right)^2 \right] \frac{1}{\sqrt{2\pi}\sigma} dv \\
= \frac{1}{\sqrt{2\pi \frac{h_n^2}{2} + \sigma^2}} \exp \left[- \frac{1}{2} \cdot \frac{(x-\mu)^2}{\frac{h_n^2}{2} + \sigma^2} \right].
\end{aligned}$$

با تغییر متغیر، داریم:

$$\mathcal{E} \left[\varphi^2 \left(\frac{x-v}{h_n} \right) \right] = \frac{h_n/\sqrt{2}}{2\pi \sqrt{h_n^2/2 + \sigma^2}} \exp \left[- \frac{1}{2} \frac{(x-\mu)^2}{h_n^2/2 + \sigma^2} \right]$$

و بنابراین نتیجه می گیریم:

$$\frac{1}{nh_n^2} \mathcal{E} \left[\varphi^2 \left(\frac{x-v}{h_n} \right) \right] = \frac{1}{nh_n} \cdot \frac{1}{2\sqrt{\pi}} \cdot \frac{1}{\sqrt{2\pi} \sqrt{h_n^2/2 + \sigma^2}} \exp \left[- \frac{1}{2} \cdot \frac{(x-\mu)^2}{h_n^2/2 + \sigma^2} \right].$$

برای مقادیر کوچک h_n ، داریم $\sqrt{h_n^2/2 + \sigma^2} \simeq \sigma$ ، بنابراین رابطه ی قبلی تقریب زده می شود به:

$$\begin{aligned}
\frac{1}{nh_n^2} \mathcal{E} \left[\varphi^2 \left(\frac{x-v}{h_n} \right) \right] &\simeq \frac{1}{nh_n 2\sqrt{\pi}} \cdot \frac{1}{\sqrt{2\pi}\sigma} \exp \left[- \frac{1}{2} \left(\frac{x-\mu}{\sigma} \right)^2 \right] \\
&= \frac{1}{2nh_n \sqrt{\pi}} p(x). \quad (*)
\end{aligned}$$

به طور مشابه داریم:

$$\begin{aligned}
\frac{1}{nh_n^2} \left\{ \mathcal{E} \left[\varphi \left(\frac{x-v}{h_n} \right) \right] \right\}^2 &= \frac{1}{nh_n^2} \cdot h_n^2 \cdot \frac{1}{\sqrt{2\pi}\sqrt{h_n^2 + \sigma^2}} \exp \left[-\frac{1}{2} \cdot \frac{(x-\mu)^2}{h_n^2 + \sigma^2} \right] \\
&= \frac{h_n}{nh_n\sqrt{2\pi}\sqrt{h_n^2 + \sigma^2}} \exp \left[-\frac{1}{2} \cdot \frac{(x-\mu)^2}{h_n^2 + \sigma^2} \right] \\
&\simeq \frac{h_n}{nh_n\sqrt{2\pi}\sigma} \exp \left[-\frac{1}{2} \cdot \frac{(x-\mu)^2}{\sigma^2} \right] \simeq 0, \quad (**)
\end{aligned}$$

که برای مقادیر کوچک h_n معتبر است. از روابط (*) و (**) داریم:

$$Var[P_n(x)] = \frac{p(x)}{2nh_n\sqrt{\pi}}$$

$$var[p_n(x)] \approx \frac{1}{2nh_n\sqrt{\pi}}p(x) \quad (\text{پ})$$

پاسخ قسمت پ:

اکنون بایاس را می نویسیم:

$$\begin{aligned}
p(x) - \bar{p}^n(x) &= \frac{1}{\sqrt{2\pi}\sigma} \exp \left[-\frac{1}{2} \cdot \frac{(x-\mu)^2}{\sigma^2} \right] - \frac{1}{\sqrt{2\pi}\sqrt{h_n^2 + \sigma^2}} \exp \left[-\frac{1}{2} \cdot \frac{(x-\mu)^2}{h_n^2 + \sigma^2} \right] \\
&= \frac{1}{\sqrt{2\pi}\sigma} \exp \left[-\frac{1}{2} \cdot \frac{(x-\mu)^2}{h_n^2 + \sigma^2} \right] \left\{ 1 - \frac{\sigma}{\sqrt{h_n^2 + \sigma^2}} \exp \left[-\frac{1}{2} \left(\frac{(x-\mu)^2}{h_n^2 + \sigma^2} + \frac{1}{2} \frac{(x-\mu)^2}{\sigma^2} \right) \right] \right\} \\
&= p(x) \left\{ 1 - \frac{1}{\sqrt{1 + (h_n/\sigma)^2}} \exp \left[-\frac{(x-\mu)^2}{2} \left(\frac{1}{h_n^2 + \sigma^2} - \frac{1}{\sigma^2} \right) \right] \right\} \\
&= p(x) \left\{ 1 - \frac{1}{\sqrt{1 + (h_n/\sigma)^2}} \exp \left[\frac{1}{2} \cdot \frac{h_n^2(x-\mu)^2}{h_n^2 + \sigma^2} \right] \right\}.
\end{aligned}$$

برای مقادیر کوچک h_n بسط مرتبه دوم انجام می دهیم:

$$\frac{1}{\sqrt{1 + \left(\frac{h_n}{\sigma}\right)^2}} \simeq 1 - \frac{1}{2} \left(\frac{h_n}{\sigma}\right)^2$$

و همچنین:

$$\exp \left(\frac{h_n^2}{2\sigma^2} \cdot \frac{(x-\mu)^2}{h_n^2 + \sigma^2} \right) \simeq 1 + \frac{h_n^2}{2\sigma^2} \cdot \frac{(x-\mu)^2}{h_n^2 + \sigma^2}$$

ما جملاتی از مرتبه بالاتر از h_n^2 را نادیده می گیریم و به نتیجه زیر می رسیم:

$$\begin{aligned}
p(x) - \hat{p}_n(x) &\simeq p(x) \left\{ 1 - \left(1 - \frac{1}{2} \left(\frac{h_n}{\sigma} \right)^2 \right) \left(1 + \frac{h_n^2}{2\sigma^2} \cdot \frac{(x - \mu)^2}{h_n^2 + \sigma^2} \right) \right\} \\
&\simeq p(x) \left\{ 1 - 1 + \frac{1}{2} \cdot \frac{h_n^2}{\sigma^2} - \frac{1}{2} \cdot \frac{h_n^2}{\sigma^2} \cdot \frac{(x - \mu)^2}{h_n^2 + \sigma^2} \right\} \\
&\simeq \frac{1}{2} \left(\frac{h_n}{\sigma} \right)^2 \left[1 - \frac{(x - \mu)^2}{h_n^2 + \sigma^2} \right] p(x) \\
&= \frac{1}{2} \left(\frac{h_n}{\sigma} \right)^2 \left[1 - \frac{(x - \mu)^2}{\sigma^2} \right] p(x)
\end{aligned}$$

سوال سه (۱۰ نمره)

توزیع یکنواخت $p(x)$ و پنجره پارزن $\varphi(x)$ به صورت زیر تعریف شده است:

$$p(x) \sim U(0, a)$$

$$\varphi(x) = \begin{cases} e^{-x}; & x > 0 \\ 0; & x \leq 0 \end{cases}$$

الف) نشان دهید که میانگین چنین تخمینی از پنجره پارزن به صورت زیر می شود.

$$\bar{p}_n(x) = \begin{cases} 0; & x < 0 \\ \frac{1}{a} \left(1 - e^{-\frac{x}{h_n}} \right); & 0 \leq x \leq a \\ \frac{1}{a} \left(e^{\frac{a}{h_n}} - 1 \right) e^{-\frac{x}{h_n}}; & a \leq x \end{cases}$$

پاسخ قسمت الف:

امید ریاضی برآورد پنجره‌ی پارزن به صورت زیر است:

$$\begin{aligned}
 \bar{p}_n(x) &= \mathbb{E} \left[\frac{1}{nh_n} \sum_{i=1}^n \varphi \left(\frac{x - x_i}{h_n} \right) \right] = \frac{1}{h_n} \int \varphi \left(\frac{x - v}{h_n} \right) p(v) dv \\
 &= \frac{1}{h_n} \int e^{-\frac{(x-v)}{h_n}} p(v) dv \\
 &= \frac{\exp \left[-\frac{x}{h_n} \right]}{h_n} \int_{0 < v < a} \frac{1}{a} \exp \left[\frac{v}{h_n} \right] dv \\
 &= \begin{cases} 0 & x < 0 \\ \frac{e^{-x/h_n}}{ah_n} \int_0^x e^{v/h_n} dv & 0 \leq x \leq a \\ \frac{e^{-x/h_n}}{ah_n} \int_0^a e^{v/h_n} dv & x \geq a \end{cases} \\
 &= \begin{cases} 0 & x < 0 \\ \frac{1}{a} (1 - e^{-x/h_n}) & 0 \leq x \leq a \\ \frac{1}{a} (e^{a/h_n} - 1) e^{-x/h_n} & x \geq a \end{cases}
 \end{aligned}$$

راهنمایی: محاسبه دو انتگرال به صورت زیر انجام شده است:

ابتدا برای انتگرال اول:

$$\int_0^x e^{v/h_n} dv$$

از تغییر متغیر استفاده می‌کنیم:

$$u = \frac{v}{h_n} \Rightarrow dv = h_n du$$

کران‌های جدید:

$$v = 0 \Rightarrow u = 0, \quad v = x \Rightarrow u = \frac{x}{h_n}$$

در نتیجه:

$$\int_0^x e^{v/h_n} dv = h_n \int_0^{x/h_n} e^u du = h_n (e^{x/h_n} - 1)$$

به‌طور مشابه، برای انتگرال دوم:

$$\int_0^a e^{v/h_n} dv = h_n (e^{a/h_n} - 1)$$

در گام اوّل، از این مفهوم استفاده کردیم که $x_1, \dots, x_n$ نمونه‌های مستقل گرفته‌شده مطابق با $p(v)$ هستند.


ب) $\bar{p}_n(x)$ را بر حسب x برای $h_n = \{1, \frac{1}{4}, \frac{1}{16}\}$ و $a = 1$ رسم کنید.

پاسخ قسمت ب:

برای حالت $a = 1$ تابع $\bar{p}_n(x)$ به صورت زیر تعریف می شود:

$$\bar{p}_n(x) = \begin{cases} 0 & x < 0 \\ 1 - e^{-x/h_n} & 0 \leq x \leq 1 \\ (e^{1/h_n} - 1)e^{-x/h_n} & x > 1 \end{cases}$$

همان طور که در شکل زیر نشان داده شده است:



با توجه به نمودار رسم شده برای تابع $\bar{p}_n(x)$ مشاهده می شود که با افزایش مقدار h_n ، شکل تابع تغییرات محسوسی دارد. تحلیل رفتار تابع نسبت به h_n به صورت زیر است:

(۱) برای مقادیر کوچکتر h_n (مانند $\frac{1}{16}$)، تابع $\bar{p}_n(x)$ به سرعت افزایش یافته و به اوج خود در بازه $0 \leq x \leq 1$ می رسد، سپس به سرعت کاهش می یابد. این نشان دهنده تمرکز بیشتر تابع حول $x = 1$ است.

(۲) با افزایش h_n ، شیب صعودی تابع در بازه $[0, 1]$ کمتر شده و مقدار اوج تابع کاهش می یابد. همچنین، تابع برای $x > 1$ دارای دنباله ای کشیده تر با کاهش کندتر است.

(۳) برای $h_n = 1$ ، تابع دارای رشد ملایم تری در بازه $[0, 1]$ است و پس از آن نیز آهسته تر کاهش می یابد. در نتیجه، تابع پراکندگی بیشتری دارد و تمرکز آن کمتر از حالت های با h_n کوچکتر است.

به طور خلاصه نتیجه می شود که، افزایش h_n باعث کاهش تمرکز تابع و افزایش پراکندگی آن می شود؛ در حالی که کاهش h_n منجر به تمرکز بیشتر تابع در نزدیکی $x = 1$ خواهد شد.

پ) h_n چه قدر باشد تا در بازه $0 \leq x < a$ مقدار بایاس کمتر از ۱ درصد باشد.

پاسخ قسمت پ:

بایاس به صورت زیر تعریف می شود:

$$p(x) - \bar{p}_n(x) = \begin{cases} 0 & x < 0 \\ \frac{1}{a} - \frac{1}{a} (1 - e^{-x/h_n}) & 0 \leq x \leq a \\ 0 - \frac{1}{a} (e^{a/h_n} - 1) e^{-x/h_n} & x \geq a \end{cases}$$

$$= \begin{cases} 0 & x < 0 \\ \frac{1}{a} e^{-x/h_n} & 0 \leq x \leq a \\ -\frac{1}{a} (e^{a/h_n} - 1) e^{-x/h_n} & x \geq a \end{cases}$$

بایاس کمتر از ۱ درصد بر روی ۹۹ درصد از بازه $0 < x < a$ به این معناست که:

$$\frac{p(x) - \bar{p}(x)}{p(x)} \leq 0.01$$

بر روی ۹۹ درصد از بازه $0 < x < a$ این شرط منجر می شود به:

$$\frac{\frac{1}{a} e^{-x/h_n}}{\frac{1}{a}} \leq 0.01$$


یا به صورت ساده تر:

$$h_n \leq \frac{0.01a}{\ln(100)}$$

و برای حالت خاص $a = 1$ ، همان طور که در شکل نشان داده شده است، خواهیم داشت:

$$h_n \leq \frac{0.01}{\ln(100)} = 0.0022$$

توجه کنید که برآورد انجام شده در محدوده ای بالاتر از $x \sim 0.01$ در حدود ۱ درصد مقدار واقعی $p(x) = 1.0$ است، که شرایط مسئله را برآورده می کند.



سوال چهار (۱۸ نمره)

ساختار الگوریتم k -نزدیک‌ترین همسایه را در نظر بگیرید. سپس به سوالات زیر پاسخ بدهید.

الف) چرا در این روش، مقدار فرد k بر مقادیر زوج ترجیح داده می‌شود؟

پاسخ قسمت الف: در الگوریتم k -نزدیک‌ترین همسایه، مقدار k تعیین می‌کند که برای پیش‌بینی برچسب یک نمونه جدید، برچسب اکثریت از میان k نمونه‌ی آموزشی نزدیک به آن انتخاب شود. در حالت دو کلاسه، اگر k زوج باشد، احتمال رخ دادن تساوی در تعداد برچسب‌های مختلف بین همسایگان وجود دارد. این موضوع باعث ابهام در تصمیم‌گیری می‌شود. اما اگر k عددی فرد باشد، چنین حالتی اتفاق نمی‌افتد و همیشه یک برچسب به عنوان اکثریت وجود دارد، لذا انتخاب نهایی قطعی‌تر و بدون نیاز به قاعده‌های اضافه برای رفع تساوی خواهد بود.

ب) آیا در این روش، هنگام آموزش و آزمون انجام *feature scaling* لازم است؟

پاسخ قسمت ب: بله، انجام *feature scaling* (مقیاس‌بندی ویژگی‌ها) در الگوریتم k -نزدیک‌ترین همسایه بسیار ضروری است، زیرا این الگوریتم کاملاً بر اساس محاسبه فاصله (معمولاً فاصله اقلیدسی) بین نقاط عمل می‌کند. اگر ویژگی‌ها دارای مقیاس‌های متفاوت باشند، ویژگی‌هایی با دامنه عددی بزرگ‌تر تأثیر بیشتری بر محاسبه فاصله خواهند داشت و در نتیجه پیش‌بینی را دچار خطا خواهند کرد. با مقیاس‌بندی داده‌ها (مثل استفاده از نرمال‌سازی یا استانداردسازی)، تمامی ویژگی‌ها در مقیاس یکسان قرار می‌گیرند و تأثیر منصفانه‌تری در محاسبه فاصله خواهند داشت.

پ) در این روش، مقادیر خیلی کوچک یا خیلی بزرگ K چه تاثیری در نتایج پیش‌بینی دارد؟

پاسخ قسمت پ: اگر مقدار K خیلی کوچک باشد (مثلاً $K = 1$)، الگوریتم حساسیت زیادی نسبت به داده‌های نویزی یا نمونه‌های پرت (*Outliers*) خواهد داشت. در نتیجه، مدل ممکن است بیش‌برازش (*overfitting*) کند و تعمیم‌پذیری ضعیفی روی داده‌های آزمون داشته باشد (*High - Variance*).

از سوی دیگر، اگر مقدار K خیلی بزرگ انتخاب شود، الگوریتم در تصمیم‌گیری خود از نمونه‌های زیادی استفاده می‌کند که ممکن است شامل نقاط متعلق به کلاس‌های مختلف باشند ($High - Bias$). این امر باعث می‌شود مدل تمایل به میانگین‌گیری و کاهش دقت طبقه‌بندی داشته باشد (کم‌برازش یا $underfitting$) بنابراین، انتخاب بهینه مقدار K بسیار مهم است و معمولاً با استفاده از اعتبارسنجی متقابل ($cross - validation$) انجام می‌شود.

ث) توضیح دهید که چرا این الگوریتم محاسبات بیشتری را در مجموعه آزمون نسبت به بخش آموزش انجام می‌دهد.

پاسخ قسمت ث: الگوریتم k -نزدیک‌ترین همسایه یک روش یادگیری غیرپارامتری و بدون آموزش صریح است ($lazy - learning$). به این معنی که در مرحله آموزش، فقط داده‌ها ذخیره می‌شوند و هیچ مدلی ساخته نمی‌شود یا هیچ پارامتری آموزش داده نمی‌شود. اما در مرحله آزمون، برای طبقه‌بندی هر نمونه جدید باید فاصله آن با تمام نمونه‌های مجموعه آموزشی محاسبه شود و نزدیک‌ترین k نمونه انتخاب شود. این کار برای هر نمونه آزمون تکرار می‌شود و نیازمند محاسبات زیاد است، مخصوصاً در مجموعه داده‌های بزرگ. بنابراین پیچیدگی محاسباتی بیشتر در مرحله آزمون است، نه آموزش.

ج) نشان دهید که برای یک مجموعه داده آموزشی به اندازه N ، خطای طبقه‌بندی k -نزدیک‌ترین همسایه، P_{kNN} ، کران بالای زیر را نتیجه می‌دهد:

$$P_B \leq P_{kNN} \leq P_B \left(2 - \frac{2}{M} \right)$$

که در آن، P_B خطای طبقه‌بندی بیز و M تعداد کلاس‌ها است. توضیح دهید که چرا این نتیجه نشان می‌دهد که k -نزدیک‌ترین همسایه با افزایش $N \rightarrow \infty$ به صورت تقریباً بهینه عمل می‌کند.

پاسخ قسمت ج: برای نشان دادن این رابطه، باید به نتایج کلاسیک در نظریه یادگیری آماری اشاره کرد. الگوریتم k -نزدیک‌ترین همسایه دارای خاصیت سازگاری جهانی $universal consistency$ است، یعنی اگر $k \rightarrow \infty$ و $k/N \rightarrow 0$ ، آنگاه خطای آن به خطای بهینه بیز (P_B) نزدیک می‌شود. رابطه فوق نشان می‌دهد که خطای الگوریتم k -نزدیک‌ترین همسایه در بدترین حالت حداکثر تا ضریب $(2 - \frac{2}{M})$ از خطای بیز بیشتر است. این ضریب برای $M = 2$ برابر با 1 است و برای $M \rightarrow \infty$ به 2 میل می‌کند. در واقع در این حالت نمونه‌های نزدیک به x در $K - NN$ تقریباً از توزیع داده‌ها نمونه‌گیری می‌کنند، و بنابراین:

$$\lim_{N \rightarrow \infty} P_{kNN} = P_B$$

بنابراین، هرچه تعداد داده‌ها زیادتر شود، الگوریتم می‌تواند به پیش‌بینی بیز که بهینه‌ترین پیش‌بینی ممکن است، نزدیک شود. چون در این حالت اگر کلاس درست، کلاس i باشد، احتمال انتخاب کلاس نادرست از $M - 1$ کلاس دیگر وجود دارد و بیشینه خطای زمانی رخ می‌دهد که احتمال اکثریت با کلاس درست برابر نباشد. برای کران پایین از آن جایی که طبقه‌بند بیز بهینه‌ترین طبقه‌بند ممکن است، هیچ طبقه‌بندی نمی‌تواند خطایی کمتر از آن داشته باشد، پس:

$$P_{kNN} \geq P_B$$

کران بالا و پایین نشان می‌دهد که عملکرد طبقه‌بند $K - NN$ از نظر خطای طبقه‌بندی، همیشه بدتر از بیز نیست و با افزایش اندازه‌ی داده‌ها، به آن نزدیک می‌شود. این نتیجه از مهم‌ترین ویژگی‌های مثبت این الگوریتم است.

ح) نشان دهید که مدل k -نزدیک‌ترین همسایه برای ($K \neq 1$) تابع توزیع نامناسبی را تعریف می‌کند که انتگرال آن در تمام فضا واگرا می‌باشد.

پاسخ قسمت ح: در روش K نزدیک‌ترین همسایه، زمانی که می‌خواهیم چگالی احتمال را در یک نقطه‌ی خاص x_i تخمین بزنیم، یک کره‌ی کوچک به مرکز x_i در نظر می‌گیریم و شعاع آن را آن‌قدر افزایش می‌دهیم تا دقیقاً شامل K نقطه از داده‌ها شود. در این صورت، مقدار چگالی احتمال در نقطه‌ی x_i به صورت زیر خواهد بود:

$$p(x_i) = \frac{K}{NV_i}$$

که در آن N تعداد کل نمونه‌ها و V_i حجم کره‌ای است که به مرکز x_i رسم شده و شامل K نقطه است. فرض می‌کنیم که V_i به اندازه‌ی کوچک است که بتوان $p(x_i)$ را درون آن تقریباً ثابت در نظر گرفت. در نتیجه، می‌توان انتگرال زیر را برای تخمین از انتگرال کل چگالی احتمال نوشت:

$$\int p(x) dx \approx \sum_{i=1}^N p(x_i) \cdot V_i = \sum_{i=1}^N \frac{K}{NV_i} \cdot V_i = K \neq 1$$

از این رابطه مشاهده می‌کنیم که اگر مقدار K برابر ۱ باشد (یعنی از روش 1NN استفاده کنیم)، چگالی احتمال به درستی نرمال‌سازی خواهد شد. توجه داشته باشید که فقط در صورتی این تقریب معتبر است که اولاً حجم کره‌ها (V_i) به اندازه‌ی کافی کوچک باشد و ثانیاً تعداد داده‌ها (N) نیز به اندازه‌ی کافی زیاد باشد. خوشبختانه، این دو شرط در روش K نزدیک‌ترین همسایه معمولاً برقرار هستند.

ه) براساس باقی مانده شماره دانشجویی شما بر عدد ۲، یکی از الگوریتم‌های زیر را انتخاب کنید و توضیح دهید و مثال بزنید که چگونه این الگوریتم می‌تواند در تسریع الگوریتم k -نزدیک‌ترین همسایه کمک کند

۰) الگوریتم $K - D Tress$

۱) الگوریتم $Inverted List$

سوال پنج (۱۲ نمره)

ساختار الگوریتم هیستوگرام را در نظر بگیرید. سپس به سوالات زیر پاسخ دهید.

الف) کران پایین کرامر-رائو^۴ بیان می‌کند که واریانس هر برآوردگر نااریب^۵ دارای یک کران پایین است. نشان دهید که واریانس برآوردگر هیستوگرام مقدار زیر را نتیجه می‌دهد:

$$VAR(\hat{p}(x)) \geq \frac{p(x)(1-p(x)V)}{NV}$$

و توضیح دهید که این نتیجه چگونه ضعف هیستوگرام‌ها را در فضاهای با ابعاد بالا نشان می‌دهد.

پاسخ قسمت الف:

کران پایین کرامر-رائو بیان می‌کند که برای هر برآوردگر نااریب $\hat{\theta}$ ، داریم:

$$\text{Var}(\hat{\theta}) \geq \frac{1}{\mathcal{I}(\theta)}$$

که در آن $\mathcal{I}(\theta)$ اطلاعات فیشر است.

در هیستوگرام، فضای ویژگی به V bin تقسیم می‌شود. اگر x در یک bin خاص باشد، احتمال آن bin برابر است با $p(x)$ و برآورد آن:

$$\hat{p}(x) = \frac{n_x}{N}$$

که $n_x \sim \text{Binomial}(N, p(x))$ است. بنابراین:

$$\text{Var}(\hat{p}(x)) = \frac{1}{N^2} \cdot \text{Var}(n_x) = \frac{p(x)(1-p(x))}{N}$$

حال با در نظر گرفتن اینکه $p(x) = f(x)V$ (یعنی حجم bin لحاظ شود):

$$\text{Var}(\hat{p}(x)) = \frac{p(x)(1-p(x)V)}{NV}$$

که همان رابطه موردنظر است:

$$\boxed{\text{Var}(\hat{p}(x)) \geq \frac{p(x)(1-p(x)V)}{NV}}$$

با افزایش بعد فضا، برای دقت بالا نیاز است bin ها کوچک شوند (یعنی $V \rightarrow 0$). در این حالت:

^۴Cramer – Rao lower bound
^۵unbiased

$$p(x) \rightarrow 0 \quad (1)$$

(۲) در هر bin تعداد نمونه‌های کمی قرار می‌گیرد.

(۳) در نتیجه واریانس $\hat{p}(x)$ افزایش می‌یابد.

بنابراین، در فضاهای با ابعاد بالا هیستوگرام‌ها برآورد ضعیفی از چگالی دارند.

(ب) تعداد بازه‌های M در یک هیستوگرام به عنوان یک پارامتر هموارسازی^۶ عمل می‌کند. با استفاده از بهینه‌سازی میانگین مربعات خطا^۷، نشان دهید که انتخاب بهینه M برای یک مجموعه داده تک‌بعدی با چگالی واقعی $p(x)$ و N نمونه به صورت زیر نتیجه می‌شود:

$$M^* = \mathcal{O}(N^{1/3})$$

پاسخ قسمت ب: فرض کنیم متغیر تصادفی X دارای تابع چگالی احتمال واقعی $p(x)$ است و از این توزیع، N نمونه‌ی مستقل و مشابه ($i.i.d.$) برداشت شده است.

می‌خواهیم توزیع احتمال را با استفاده از هیستوگرام تخمین بزنیم، که در آن بازه‌ی تعریف شده برای دامنه‌ی x به M بخش مساوی تقسیم می‌شود. هدف، انتخاب مقدار بهینه‌ای از M است، به طوری که خطای میانگین مربعات بین چگالی تخمینی و چگالی واقعی مینیمم شود.

تابع چگالی تخمینی را با $\hat{p}_M(x)$ نشان می‌دهیم. خطای میانگین مربعات به صورت زیر تعریف می‌شود:

$$MSE(x) = \mathbb{E} [(\hat{p}_M(x) - p(x))^2]$$

می‌توان این خطا را به صورت مجموع بایاس و واریانس نوشت:

$$MSE(x) = (\mathbb{E}[\hat{p}_M(x)] - p(x))^2 + \mathbb{V}[\hat{p}_M(x)]$$

و در کل، خطای کلی برابر است با:

$$MSE = \int MSE(x) dx = \int (Bias^2(x) + Var(x)) dx$$

فرض کنیم بازه‌ی کل $[a, b]$ به M بازه‌ی مساوی با طول $h = \frac{b-a}{M}$ تقسیم شود. برای هر بازه، تعداد نمونه‌هایی که در آن بازه می‌افتند، یک متغیر دوجمله‌ای با احتمال تقریباً $p(x)h$ است. بنابراین، برای بازه‌ی i -ام، چگالی تخمینی برابر است با:

$$\hat{p}_M(x) = \frac{k_i}{Nh}$$

^۶smoothing
^۷Mean Squared Error

که در آن k_i تعداد نمونه‌های واقع شده در بازه‌ی i است.
 حال:

واریانس این تخمین:

$$Var(\hat{p}_M(x)) \approx \frac{p(x)}{Nh}$$

بایاس این تخمین (با فرض هموار بودن $p(x)$):

$$Bias(\hat{p}_M(x)) \approx \frac{h^2}{24} p''(x) \Rightarrow Bias^2 \propto h^4$$

ترکیب دو عبارت بالا:

$$MSE \propto \underbrace{h^4}_{Bias^2} + \underbrace{\frac{1}{Nh}}_{Var}$$

حال این تابع را نسبت به h مینیمم می‌کنیم:

$$\frac{d}{dh} \left(h^4 + \frac{1}{Nh} \right) = 4h^3 - \frac{1}{Nh^2} = 0$$

$$\Rightarrow 4h^5 = \frac{1}{N} \Rightarrow h \propto N^{-1/5}$$

اما چون $M = \frac{1}{h} \Rightarrow M \propto N^{1/5}$

در منابع دقیق‌تر، این تحلیل منجر به رابطه‌ای با توان $\frac{1}{3}$ می‌شود که در حالت بهینه‌سازی دقیق‌تر و در نظر گرفتن ویژگی‌های تابع $p(x)$ بدست می‌آید:

$$M^* = \mathcal{O}(N^{1/3})$$

پ) فرض کنید داده‌های ما در یک فضای d -بعدی قرار دارند و ما m بازه در هر بعد انتخاب می‌کنیم. نشان دهید که تعداد کل بازه‌ها به صورت نمایی رشد می‌کند:

$$M = m^d$$

و توضیح دهید که چرا این موضوع باعث می‌شود که برآورد چگالی مبتنی بر هیستوگرام در ابعاد بالا غیرعملی شود.

فرض کنید داده‌های ما در یک فضای d -بعدی قرار دارند. اگر در هر بعد بازه‌هایی به تعداد m انتخاب کنیم، آنگاه تعداد کل بازه‌ها به صورت ضرب دکارتی تمام ابعاد به صورت زیر خواهد بود:

$$M = m^d \quad (1)$$

بنابراین، اگر بخواهیم تعداد بازه‌ها در هر بعد را افزایش دهیم، تعداد کل بازه‌ها به صورت نمایی با بعد افزایش می‌یابد. این پدیده به نام نفرین ابعاد *Curse of Dimensionality* شناخته می‌شود. در نتیجه، چگال‌سازی هیستوگرام در فضاهای با ابعاد بالا بسیار دشوار می‌شود، چرا که:

(۱) حجم هر سلول بسیار کوچک می‌شود.

(۲) تعداد نمونه‌های موردنیاز برای پر کردن بازه‌ها به صورت نمایی افزایش می‌یابد.

(۳) اکثر سلول‌ها خالی باقی می‌مانند که باعث افزایش خطای واریانس می‌شود.

در مجموع، ساختار هیستوگرام در ابعاد بالا برای برآورد چگالی، کارایی خود را از دست می‌دهد و نیاز به روش‌های پیچیده‌تر مانند kernel density estimation احساس می‌شود.

سوال شش (۴۰ نمره)

در یک آزمایشگاه تحقیقاتی دانشگاه علم و صنعت، تیمی از دانشجویان در تلاش بودند تا مدل پیش‌بینی گر قدرتمندی برای تحلیل داده‌های ناشناخته توسعه دهند. برای این منظور، آن‌ها تصمیم گرفتند از روش k -نزدیک‌ترین همسایه استفاده کنند.

یکی از اعضای تیم، مأموریت ویژه‌ای بر عهده داشت: او باید نوتبوک k -نزدیک‌ترین همسایه را از این لینک باز کرده و مراحل تعیین شده را با دقت اجرا می‌کرد. چالش اصلی این بود که پس از پردازش داده‌ها، مدل باید روی مجموعه‌ای از داده‌های آزمایشی که در فایل *test.csv* قرار داشت، پیش‌بینی‌هایی انجام می‌داد. نتایج این پیش‌بینی‌ها باید در یک فایل خروجی به نام *result.csv* ذخیره می‌شد؛ فایلی که تنها یک ستون با نام *target* داشت. لطفاً به این فرد در به انجام رساندن این مأموریت کمک کنید.