

به نام خدا



دانشگاه علم و صنعت ایران
دانشکده مهندسی کامپیوتر

یادگیری ماشین

نیمسال دوم ۰۳-۰۴

استاد: جناب آقای دکتر امیرخانی

دستیار استاد: علی اثنی عشری

مهلت ارسال: ۸ فروردین ماه

تخمین

تمرین دوم

- مهلت ارسال پاسخ تا ساعت ۲۳:۵۹ مشخص شده است.
- هم کاری و هم فکری در انجام تمرین مانعی ندارد اما پاسخ ارسالی هر فرد باید توسط خود او نوشته شده باشد.
- در صورت هم فکری یا استفاده از منابع خارج از درس، نام هم فکران و آدرس منابع مورد استفاده را ذکر کنید.
- برای دریافت نمره کامل هر سوال نیاز است تمامی روابط و فرمول ها نوشته شده و توضیحات تشریحی کامل داده شود.
- لطفاً تصویری واضح از پاسخ سوالات نظری بارگذاری کنید. در غیر این صورت پاسخ شما تصحیح نخواهد شد. (برگه پاسخ سوالات نظری به صورت حضوری دریافت می گردد.)
- پاسخ تمام سوالات را در یک فایل فشرده به صورت ML_Hw2_[firstName]_[lastName]_[StudentId] نامگذاری کرده و ارسال کنید.

سوالات نظری

سوال یک (۸ نمره)

فرض کنید تابع چگالی احتمال متغیر تصادفی Y به شکل زیر است.

$$f_Y(y|\theta) = \begin{cases} \frac{1}{\theta} r y^{r-1} e^{-\frac{y}{\theta}}, & \theta > 0, y > 0 \\ 0, & elsewhere \end{cases}$$

که r یک ثابت مثبت است.

الف) تابع $\log likelihood$ را به دست بیاورید.

ب) توضیح دهید در چه حالتی و چرا تخمین گر مقدار بر آورد بیشینه احتمال پسین^۱ به تخمین گر درست نمایی بیشینه^۲ میل می کند.

سوال دو (۱۲ نمره)

توزیع نرمال $p(x) \sim N(\mu, \sigma^2)$ و پنجره پارزن $\varphi(x) \sim N(0, 1)$ را در نظر بگیرید. نشان دهید که تخمین پنجره پارزن^۳ زیر

$$p(x) = \frac{1}{nh_n} \sum_{i=1}^n \varphi\left(\frac{x - x_i}{h_n}\right)$$

برای h_n های کوچک دارای ویژگی های زیر است :

الف) $p_n^{\sim}(x) \sim N(\mu, h_n^2 + \sigma)$

ب) $p_n(x) - p_n^{\sim}(x) \approx \frac{1}{2} \left(\frac{h_n}{\sigma}\right)^2 \left[1 - \left(\frac{x-\mu}{\sigma}\right)^2\right] p(x)$

پ) $var[p_n(x)] \approx \frac{1}{2nh_n\sqrt{\pi}} p(x)$

سوال سه (۱۰ نمره)

توزیع یکنواخت $p(x)$ و پنجره پارزن $\varphi(x)$ به صورت زیر تعریف شده است:

$$p(x) \sim U(0, a)$$

$$\varphi(x) = \begin{cases} e^{-x}; & x > 0 \\ 0; & x \leq 0 \end{cases}$$

الف) نشان دهید که میانگین چنین تخمینی از پنجره پارزن به صورت زیر می شود.

$$\bar{p}_n(x) = \begin{cases} 0; & x < 0 \\ \frac{1}{a} \left(1 - e^{-\frac{x}{h_n}}\right); & 0 \leq x \leq a \\ \frac{1}{a} \left(e^{\frac{a}{h_n}} - 1\right) e^{-\frac{x}{h_n}}; & a \leq x \end{cases}$$

ب) $\bar{p}_n(x)$ را بر حسب x برای $h_n = \{1, \frac{1}{4}, \frac{1}{16}\}$ و $a = 1$ رسم کنید.

پ) h_n چه قدر باشد تا در بازه $0 \leq x < a$ مقدار بایاس کمتر از ۱ درصد باشد.

^۱Maximum A Posteriori Estimation

^۲Maximum Likelihood Estimation

^۳Parzen Window – based Estimation

سوال چهار (۱۸ نمره)

ساختار الگوریتم k -نزدیک‌ترین همسایه را در نظر بگیرید. سپس به سوالات زیر پاسخ بدهید.

(الف) چرا در این روش، مقدار فرد k بر مقادیر زوج ترجیح داده می‌شود؟

(ب) آیا در این روش، هنگام آموزش و آزمون انجام $feature\ scaling$ لازم است؟

(پ) در این روش، مقادیر خیلی کوچک یا خیلی بزرگ K چه تاثیری در نتایج پیش‌بینی دارد؟

(ث) توضیح دهید که چرا این الگوریتم محاسبات بیشتری را در مجموعه آزمون نسبت به بخش آموزش انجام می‌دهد.

(ج) نشان دهید که برای یک مجموعه داده آموزشی به اندازه N ، خطای طبقه‌بندی k -نزدیک‌ترین همسایه، P_{kNN} ، کران بالایی زیر را نتیجه می‌دهد:

$$P_B \leq P_{kNN} \leq P_B \left(2 - \frac{2}{M} \right)$$

که در آن، P_B خطای طبقه‌بندی بیز و M تعداد کلاس‌ها است. توضیح دهید که چرا این نتیجه نشان می‌دهد که k -نزدیک‌ترین همسایه با افزایش $N \rightarrow \infty$ به صورت تقریباً بهینه عمل می‌کند.

(ح) نشان دهید که مدل k -نزدیک‌ترین همسایه برای $(K \neq 1)$ تابع توزیع نامناسبی را تعریف می‌کند که انتگرال آن در تمام فضا واگرا می‌باشد.

(ه) براساس باقی‌مانده شماره دانشجویی شما بر عدد ۲، یکی از الگوریتم‌های زیر را انتخاب کنید و توضیح دهید و مثال بزنید که چگونه این الگوریتم می‌تواند در تسریع الگوریتم k -نزدیک‌ترین همسایه کمک کند

(۰) الگوریتم $K - D Tress$

(۱) الگوریتم $Inverted List$

سوال پنج (۱۲ نمره)

ساختار الگوریتم هیستوگرام را در نظر بگیرید. سپس به سوالات زیر پاسخ بدهید.

(الف) کران پایین کرامر-رائو^۴ بیان می‌کند که واریانس هر برآوردگر ناریب^۵ دارای یک کران پایین است. نشان دهید که واریانس برآوردگر هیستوگرام مقدار زیر را نتیجه می‌دهد:

$$VAR(\hat{p}(x)) \geq \frac{p(x)(1-p(x)V)}{NV}$$

^۴Cramer – Rao lower bound
^۵unbiased

و توضیح دهید که این نتیجه چگونه ضعف هیستوگرام‌ها را در فضاهای با ابعاد بالا نشان می‌دهد.

ب) تعداد بازه‌های M در یک هیستوگرام به عنوان یک پارامتر هموارسازی^۶ عمل می‌کند. با استفاده از بهینه‌سازی میانگین مربعات خطا^۷، نشان دهید که انتخاب بهینه M برای یک مجموعه داده تک‌بعدی با چگالی واقعی $p(x)$ و N نمونه به صورت زیر نتیجه می‌شود:

$$M^* = \mathcal{O}(N^{1/3})$$

پ) فرض کنید داده‌های ما در یک فضای d -بعدی قرار دارند و ما m بازه در هر بعد انتخاب می‌کنیم. نشان دهید که تعداد کل بازه‌ها به صورت نمایی رشد می‌کند:

$$M = m^d$$

و توضیح دهید که چرا این موضوع باعث می‌شود که برآورد چگالی مبتنی بر هیستوگرام در ابعاد بالا غیرعملی شود.

سوال شش (۴۰ نمره)

در یک آزمایشگاه تحقیقاتی دانشگاه علم و صنعت، تیمی از دانشجویان در تلاش بودند تا مدل پیش‌بینی‌گر قدرتمندی برای تحلیل داده‌های ناشناخته توسعه دهند. برای این منظور، آن‌ها تصمیم گرفتند از روش k -نزدیک‌ترین همسایه استفاده کنند.

یکی از اعضای تیم، مأموریت ویژه‌ای بر عهده داشت: او باید نوتبوک k -نزدیک‌ترین همسایه را از این لپ‌تاپ باز کرده و مراحل تعیین‌شده را با دقت اجرا می‌کرد. چالش اصلی این بود که پس از پردازش داده‌ها، مدل باید روی مجموعه‌ای از داده‌های آزمایشی که در فایل `test.csv` قرار داشت، پیش‌بینی‌هایی انجام می‌داد. نتایج این پیش‌بینی‌ها باید در یک فایل خروجی به نام `result.csv` ذخیره می‌شد؛ فایلی که تنها یک ستون با نام `target` داشت. لطفاً به این فرد در به انجام رساندن این مأموریت کمک کنید.

^۶smoothing
^۷Mean Squared Error