

به نام خدا



یادگیری ماشین

نیمسال دوم ۰۴-۰۳

استاد: جناب آقای دکتر امیرخانی

دستیار استاد: اثنی عشری - ستاری

مهلت ارسال: ۵ اردیبهشت

رگرسیون

تمرین سوم

- مهلت ارسال پاسخ تا ساعت ۲۳:۵۹ مشخص شده است.
- هم کاری و هم فکری در انجام تمرین مانعی ندارد اما پاسخ ارسالی هر فرد باید توسط خود او نوشته شده باشد.
- در صورت هم فکری یا استفاده از منابع خارج از درس، نام هم فکران و آدرس منابع مورد استفاده را ذکر کنید.
- برای دریافت نمره کامل هر سوال نیاز است تمامی روابط و فرمول ها نوشته شده و توضیحات تشریحی کامل داده شود.
- دانشجویان یا باید سوالات را کامل به صورت تایپ شده یا کامل به صورت دست نویس ارسال کنند. برگه دوستانی که به صورت دست نویس ارسال کرده اند به صورت حضوری دریافت خواهد شد.
- توجه شود که برای ارزیابی سوال امتیازی و سوال عملی، از دانشجویان عزیز ارائه خواهیم گرفت.
- پاسخ تمام سوالات را در یک فایل فشرده به صورت `ML_Hw3_[firstName]_[lastName]_[StudentId]` نامگذاری کرده و ارسال کنید.

سوالات نظری

سوال یک (۱۲ نمره)

یک معلم ریاضی زمان لازم، y دقیقه، برای رفتن به مدرسه را زمانی که x دقیقه بعد از ساعت ۷ صبح از خانه خارج می شد، در هفت زمان متفاوت ثبت کرده است. داده های ثبت شده در جدول زیر آمده است:

۶۰	۵۰	۴۰	۳۰	۲۰	۱۰	۰	x
۵۱	۴۸	۳۹	۳۹	۲۸	۲۷	۱۶	y

۱. نمودار پراکندگی *ScatterPlot*

الف) داده های داده شده را روی یک نمودار پراکندگی رسم کنید.

۲. رگرسیون کمترین مربعات *LeastSquaresRegression*

الف) معادله خط رگرسیون کمترین مربعات y بر حسب x را به دست آورید و آن را به صورت $y = a + bx$ بنویسید.

ب) خط رگرسیون را روی نمودار پراکندگی خود رسم کنید.

۳. محدودیت زمان رسیدن به مدرسه *ArrivalTimeConstraint*

معلم باید حداکثر تا ساعت ۸:۴۰ صبح به مدرسه برسد.

الف) نشان دهید که تعداد دقیقی که معلم زودتر به مدرسه می‌رسد، که با z نشان داده می‌شود، به صورت زیر است:

$$z = (100 - a) - (1 + b)x$$

ب) با استفاده از این معادله، بیشترین زمانی را که معلم می‌تواند از خانه خارج شود، به دقیقه (نزدیک‌ترین عدد صحیح)، به طوری که دیر به مدرسه نرسد، برآورد کنید.

سوال دو (۱۳ نمره)

الف) تابع سیگموئید داده شده در زیر را

$$\frac{1}{1 + e^{-wX}}$$

را بر حسب $X \in \mathbb{R}$ ، برای $w \in \{1, 5, 100\}$ رسم کنید و استدلال کنید چرا جواب با وزن‌های بزرگ می‌تواند *logistic regression* را دچار بیش‌برازش کند؟

ب) چرا در حالتی که تمام ویژگی‌ها تا حد خوبی با خروجی مرتبط هستند، رگرسیون *Ridge* به رگرسیون *Lasso* ترجیح داده می‌شود؟

پ) پیش‌بینی می‌شود که رابطه‌ای خطی بین ساعات مطالعه به‌عنوان متغیر مستقل (x) و نمره یک درس به‌عنوان متغیر وابسته (y) وجود دارد. ۱۲ نفر دانشجو مورد تحقیق و بررسی قرار گرفتند. با توجه به مشاهدات زوجی (x, y) مقادیر زیر محاسبه شده‌اند:

$$S_{xx} = 30 \quad S_{yy} = 120 \quad S_{xy} = 48$$

ضریب تعیین در این وابستگی را بیابید.

ج) برای برازش یک مدل خطی ساده به فرم $y = \alpha + \beta x + \varepsilon$ بر اساس یک نمونه تصادفی ۲۵ تایی خلاصه اطلاعات زیر حاصل شده است. مقدار $(\hat{\alpha}, SSE)$ را بیابید.

$$S_x^2 = \sum (x_i - 4)^2 = 36 \quad S_y^2 = \sum (y_i - 6)^2 = 64 \quad S_{xy} = \sum (x_i - 4)(y_i - 6) = 25$$

overfit

سوال سه (۱۰ نمره)

فرض کنید n داده آموزشی با m ویژگی داریم. مقدار هدف^۲ به صورت یک بردار^۳ تعریف می شود:

$$y = [y^{(0)}, \dots, y^{(n)}] \in \mathbb{R}^n$$

و داده های نمونه به صورت زیر داده شده اند:

$$X = [x^{(0)}; \dots; x^{(n)}] \in \mathbb{R}^{n \times m}.$$

در اینجا، x_j ستون j -ام این ماتریس را نشان می دهد.

(الف) نشان دهید که اگر رگرسیون را فقط بر روی یکی از ویژگی ها (از بین m ویژگی) آموزش دهیم، خواهیم داشت:

$$w_j = \frac{x_j^T y}{x_j^T x_j}$$

(ب) فرض کنید که ستون های ماتریس X متعامد^۴ هستند. ثابت کنید که پارامترهای بهینه حاصل از آموزش رگرسیون روی تمام ویژگی ها با پارامترهای بهینه حاصل از آموزش روی هر ویژگی به صورت مستقل یکسان هستند.

سوال چهار (۱۰ نمره)

فرض کنید مجموعه داده ای از ۵۰ مشاهده با دو ویژگی X_1 و X_2 و یک متغیر باینری Y دارید. شما می خواهید یک مدل رگرسیون لجستیک برای پیش بینی Y بر اساس X_1 و X_2 بسازید. مدل به صورت زیر تعریف می شود:

$$p(Y = 1 | X_1, X_2) = \frac{1}{1 + e^{-(b_0 + b_1 X_1 + b_2 X_2)}}$$

(الف) (۳ نمره) تابع احتمال را برای این مدل بنویسید.

(ب) (۳ نمره) گرادیان تابع درستمایی را استخراج کنید.

(پ) (۴ نمره) الگوریتم صعود گرادیان را برای تخمین ضرایب b_0, b_1 و b_2 اجرا کنید.

سوال پنج (۲۰ نمره)

در یک مدل رگرسیون خطی با ویژگی های x_i داریم:

$$y = \sum_{i=1}^p w_i x_i + \epsilon = w^T x + \epsilon$$

در صورتی که نویز موجود دارای توزیع $\epsilon \sim \mathcal{N}(0, \sigma^2)$ باشد، مشخصاً خواهیم داشت:

^۲target value
^۳vector
^۴orthogonal

$$y|x, w \sim \mathcal{N}(w^T x, \sigma^2)$$

با در نظر گرفتن تمام نمونه‌های آموزشی می‌توان این عبارت را برای همه آن‌ها بنویسیم و در نتیجه به صورت برداری خواهیم داشت:

$$Y|X, w \sim \mathcal{N}(Xw, \sigma^2 I_n)$$

که در عبارت بالا $w \in \mathbb{R}^p$ ، $X \in \mathbb{R}^{n \times p}$ ، و $y \in \mathbb{R}^n$ می‌باشد.

(الف) توزیع بالا به چه معناست؟

توجه: در ۳ بخش بعدی جواب خود را به صورت یک مسئله بهینه‌سازی کمترین مربعات (که می‌تواند همراه با یک جمله *regularizer* باشد) بنویسید و نیازی به محاسبه $\hat{w}_{MLE}$ و $\hat{w}_{MAP}$ نیست.

(ب) تخمین MLE را برای w بدست بیاورید. این مسئله معادل با کدام حالت روش رگرسیون است؟

(پ) فرض کنید برای پارامترهای w یک توزیع اولیه (*Prior*) در نظر می‌گیریم؛ به طوری که:

$$w \sim \mathcal{N}(\cdot, \lambda^2 I_p).$$

تخمین MAP را برای w بدست آورید. این مسئله معادل با کدام حالت روش رگرسیون است؟

(ج) حال توزیع اولیه را تغییر می‌دهیم. فرض کنید که هر یک از وزن‌ها دارای توزیع زیر باشد:

$$w_i \sim \text{Laplace}(\cdot, \lambda)$$

تخمین MAP را برای w بدست آورید. این مسئله معادل با کدام حالت روش رگرسیون است؟

(د) تفاوت بین استفاده از این دو توزیع را از دیدگاه اثر آن‌ها بر روی اندازه w_i ها به صورت خلاصه توضیح دهید.

راهنمایی:

$$Z \sim \text{Laplace}(\cdot, \lambda) \quad \Rightarrow \quad f_Z(z) = \frac{1}{2\lambda} \exp\left(-\frac{|z|}{\lambda}\right)$$

$$Z \sim \mathcal{N}(\mu, \Sigma) \quad \Rightarrow \quad f_Z(\mathbf{z}) = \frac{1}{(2\pi)^{n/2} |\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(\mathbf{z} - \mu)^T \Sigma^{-1}(\mathbf{z} - \mu)\right)$$

سوال ششم (۳۵ نمره)

علی که به تازگی درس یادگیری ماشین را در دانشگاه سپری کرده است، در یک شرکت مشاور املاک، با چالشی جدید مواجه شده است. مدیران شرکت از او خواسته‌اند که الگویی برای پیش‌بینی قیمت آپارتمان‌ها در تهران ارائه دهد. این تصمیم به دنبال تغییرات اخیر در بازار مسکن گرفته شده است، جایی که نوسانات قیمتی غیرقابل پیش‌بینی، خرید و فروش املاک را دشوار کرده است. برای انجام این تحلیل، علی به یک مجموعه داده شامل اطلاعات مربوط به آپارتمان‌های فروخته‌شده در نقاط مختلف تهران دسترسی دارد که از این لینک قابل دسترسی است. مجموعه داده مذکور شامل ویژگی‌های زیر است:

■ متراژ خانه به متر (*Area*)

■ تعداد اتاق خواب (*Room*)

■ پارکینگ دارد یا خیر (*Parking*)

■ انباری دارد یا خیر (*Warehouse*)

■ آسانسور دارد یا خیر (*Elevator*)

■ آدرس محدوده در تهران (*Address*)

■ قیمت به تومان (*Price*)

■ قیمت به دلار (*Price_USD*)

علی متوجه شد که برخی از داده‌ها ممکن است ناقص یا دارای مقادیر پرت باشند. همچنین، ویژگی‌هایی مانند داشتن پارکینگ یا آسانسور، احتمالاً تأثیر مستقیمی بر قیمت آپارتمان‌ها دارند. بنابراین، او تصمیم گرفت داده‌ها را تحلیل، پردازش و تمیز کند تا بتواند یک مدل قابل اعتماد برای پیش‌بینی قیمت آپارتمان‌ها توسعه دهد. لطفاً کد مراحل زیر را درون فایل *ipynb* نوشته و با گرفتن تمام خروجی‌ها آپلود نمایید.

۶-۱. بررسی اولیه داده‌ها

(آ) داده‌ها را به صورت یک *DataFrame* بخوانید.

(ب) اطلاعات کلی و آماری مجموعه داده را نمایش دهید.

۶-۲. تحلیل توزیع داده‌ها

(آ) نمودار توزیع آماری متراژ خانه‌ها (*histogram*) را رسم کنید.

(ب) یک نمودار جعبه‌ای (*boxplot*) برای قیمت آپارتمان‌ها بکشید تا مقادیر پرت شناسایی شوند.

(ج) یک نمودار *jointplot* بین قیمت و متراژ خانه‌ها رسم کنید.

(د) نمودارهای دیگری شامل *correlation plot* و *bar plot* برای درک بهتر توزیع داده‌ها رسم کنید.

۳-۶. پیش پردازش داده‌ها

- (آ) مقادیر گمشده (مانند آدرس‌های ناقص) را بوسیله روش‌های جانهی مدیریت کنید.
- (ب) مقادیر پرت (مانند متراژهای غیرواقعی) را شناسایی و اصلاح کنید.
- (ج) ویژگی‌های باینری (*Elevator, Warehouse, Parking*) را به مقدارهای عددی (0 و 1) تبدیل کنید.
- (د) اگر مقدارهای غیر عددی دیگری وجود دارند (مثلاً آدرس)، آن‌ها را به فرمت مناسب تبدیل کنید.
- (ه) از روش‌های استانداردسازی داده‌ها برای بهبود عملکرد مدل استفاده کنید.

۴-۶. تحلیل روابط بین متغیرها

- (آ) یک *pairplot* برای تمامی متغیرهای عددی رسم کنید.
- (ب) بررسی کنید که کدام ویژگی بیشترین تأثیر را روی قیمت دارد.

۵-۶. تقسیم داده‌ها به ویژگی‌ها و لیبِل

- (آ) داده‌ها را به دو بخش ویژگی‌ها (X) و متغیر هدف (y) تقسیم کنید.

۶-۶. تقسیم داده‌ها به بخش آموزش و تست

- (آ) داده‌ها را با استفاده از *train_test_split* از *sklearn.model_selection* به دو بخش آموزش (۷۰ درصد) و تست (۳۰ درصد) تقسیم کنید.
- (ب) از *random_state = 101* استفاده کنید تا نتایج قابل تکرار باشند.

۷-۶. مدل‌سازی

- (آ) یک مدل رگرسیون خطی ایجاد کنید و داده‌ها را روی آن آموزش دهید.
- (ب) علاوه بر رگرسیون خطی، سه مدل دیگر شامل *Lasso*، *Ridge* و *Elastic Net Regression* را اعمال کنید.
- (ج) ضرایب مدل را استخراج کرده و بررسی کنید که کدام متغیرها بیشترین تأثیر را در قیمت دارند.
- (د) جدولی از هایپرپارامترهای استفاده‌شده در هر مدل ارائه دهید.

۸-۶. پیش‌بینی قیمت خانه‌ها

- (آ) قیمت آپارتمان‌های بخش تست را پیش‌بینی کنید.
- (ب) نمودار *ScatterPlot* از قیمت واقعی در مقابل قیمت پیش‌بینی‌شده رسم کنید.

۶-۹. ارزیابی مدل

(آ) اعمال چهار مدل $Lasso$ ، $Ridge$ ، $Linear Regression$ و $Elastic Net Regression$ بر روی داده‌های آموزشی و ارزیابی عملکرد آن‌ها بر روی داده‌های تست (مقایسه هر ۴ مدل در یک جدول). شاخص‌های مقایسه شامل:

$RMSE$ ■

MSE ■

R^2 ■

$HuberLoss$ ■

(ب) خطای آموزش و تست را محاسبه کرده و در قالب $Train - Test Error Plot$ نمایش دهید.

سوالات امتیازی

سوال هفت

تابع هزینه مسئله رگرسیون خطی به صورت زیر تعریف می‌شود:

$$\mathbb{L}_1(w) = \|y - Xw\|_2^2$$

می‌توانیم چند عنصر دیگر به عنوان $Regularization Term$ به این تابع هزینه اضافه کنیم. به این صورت خواهیم داشت:

$$\mathbb{L}_2(w) = \|y - Xw\|_2^2 + \|\Gamma w\|_2^2$$

که به Γ ، $Tikhonov matrix$ می‌گویند. این حالت کلی مسئله $ridge regression$ است که در اینجا به جای λ از یک ماتریس استفاده می‌کنیم. برای آموزش مدل رگرسیون خطی خود، می‌خواهیم از تکنیکی به نام $dropout$ استفاده کنیم. این تکنیک برای ورودی d بعدی، هر ویژگی را با احتمال p نگه داشته و در غیر این صورت برابر صفر خواهد شد. با استفاده از این تکنیک، تابع هزینه به شکل زیر تغییر خواهد کرد:

$$\mathbb{L}_3(w) = E_{D \sim Bernoulli(p)} [\|y - (D \odot X)\hat{w}\|_2^2]$$

توجه کنید در اینجا $\hat{w}$ پارامترهای پیدا شده توسط مدلی است که با $dropout$ آموزش داده شده است. همچنین ضرب $\odot$ ، $element wise$ می‌باشد.

(الف) ابتدا معادله نرمال برای حل مساله $minimization$ بدون توجه به $dropout$ به دست آورید. در اینجا شما مانند دیگر مسئله‌های رگرسیون، باید وزن‌های بهینه w را با استفاده از مشتق و ... با استفاده از تابع هزینه به دست آورید.

(ب) یک شرط ساده، کافی و لازم برای ماتریس Γ بیان کنید که تضمین کند تابع هزینه یک جواب منحصر به فرد و بهینه برای $\hat{w}$ دارد.

(ج) حال اثبات کنید هنگام استفاده از تکنیک *dropout*، می‌توان تابع هزینه را به شکل زیر بازنویسی کرد:

$$\mathbb{L}(w) = \|y - pX\hat{w}\|_2^2 + p(1-p)\|\hat{\Gamma}\hat{w}\|_2^2$$

به طوری که $\hat{\Gamma}$ یک ماتریس قطری بوده که عنصر j ام قطری این ماتریس، برابر نرم ستون j ام ماتریس X دادگان می‌باشد.

(د) فرض کنید Γ معکوس پذیر باشد. با یک تغییر متغیر سعی کنید تا تابع هزینه گفته شده در حالت بدون *dropout* را به صورت تابع هزینه مسئله *ridge regression* بازنویسی کنید:

$$\mathbb{L}(\hat{w}) = \|y - \hat{X}\hat{w}\|_2^2 + \lambda\|\hat{w}\|_2^2$$